

中間報告書

創域理工学研究科 情報計算科学専攻 1年
学籍番号：6326521
砂川恵太朗

提出日：2026年8月28日

1 要旨

近年、大規模言語モデル（LLM）に代表される深層生成 AI は目覚ましい性能を示しているものの、その運用に必要な膨大な計算資源とデータ量、および「破滅的忘却」といった脳科学的な乖離が課題となっている。本研究では、脳の低電力インメモリ計算およびイベント駆動型スパース処理を模倣するスパイクニューラルネットワーク（SNN）と、自己組織化的なオンライン学習を可能にする「予測符号化理論（Predictive Coding）」を統合した、新しい音声・聴覚認知システムの構築を目指す。

筆者らの先行研究では、手書き数字画像タスクにおいて双方向予測符号化モデル（Diff-bPC）の実装と評価を行ってきた。本研究は、これを時間軸方向の動的なパターンの処理に必要な「音声認識」タスクへと拡張するものである。

具体的には、人間の耳から聴覚野、言語野にいたる情報処理流を模倣した4つのステージ（Stage 1~4）からなる脳型音声認識システムを構築する。現在までに、生体模倣聴覚符号化（BAE）を用いた音声のスパイク化（Stage 1）の実装を完了し、時間予測に基づく自律学習則である Predictive E-prop（Stage 2）の再現・調整を行っている。本稿では、各パーツの詳細な構成、現在までの進捗状況、および OpenNeuro 公開の「Podcast」ECoG（頭蓋内脳電図）データセットを用いた脳機能機能的アライメント（相関解析）の評価計画について報告する。

2 背景と目的

現在、主流となっている人工知能（AI）や大規模言語モデル（LLM）は、特定のタスクや推論において人間を凌駕する性能に到達している。しかし、その成功は数ギガワット級の巨大な計算インフラと膨大な炭素排出を伴うものであり（Patterson et al., 2021）、極めて高い計算資源コストとエネルギー非効率性に直面している。また、これらのモデルは数兆トークンに及ぶ莫大なデータから表現を学習する一方、生体脳のように限られたサンプルから効率的に汎化（Few-shot 学習）する柔軟性を欠いている（Lake et al., 2017）。さらに、新しい環境や追加のタスクに適応させようとすると、既存の学習済み表現が破壊的に上書きされる「破滅的忘却」が深刻な問題となっている（McCloskey & Cohen, 1989; van de Ven et al., 2024）。

これに対し、人間の脳は約 20W という極めて微小な電力で動作し、リアルタイムに外界の複雑なマルチモーダル情報を認識・処理する（Herculano-Houzel, 2011）。この圧倒的なエネルギー効率の源泉は、フォン・ノイマン・ボトルネックを克服したシナプス結合による「インメモリ計算」と、必要な情報が到来したときのみスパイクを介して非同期的に通信・計算を行う「イベント駆動型スパース処理」にある。

この生体脳の卓越した特性を模倣するために、第三世代のニューラルネットワークであるスパイクニューラルネットワーク（SNN）が近年活発に研究されている。SNN は、時間情報を伴う $\{0, 1\}$ （あるいは極性を持つ $\{-1, 0, 1\}$ ）のパルス状信号である「スパイク」で通信を行う。これにより計算負荷を飛躍的に削減できるが、微分不可能という数学的障壁のため、大域的な「誤差逆伝播法（Backpropagation）」の直接的な適用が極めて困難である。また、誤差逆伝播法はネットワーク全体で詳細な大域的誤差情報を即座に共有する必要があり、生体脳のシナプスが局所的な（ローカルな）情報のみで自己組織的に学習している事実（生物学的妥当性）ともミスマッチしている。

この課題を解決する有力なアプローチが、脳の認知理論である「予測符号化理論（Predictive Coding）」である（Srinivasan et al., 1982; Millidge et al., 2021）。予測符号化は、上位層からのトップダウンの「予測」

と、感覚入力との「予測誤差」を直近の層間で局所的に最小化することで、大域的な誤差共有なしに表現学習を実現する。

本研究は、筆者らの先行研究である画像ベースの双方向予測符号化 SNN「Difference Bi-Predictive Coding (Diff-bPC)」の知見を基盤とする。静的な空間パターン（画像）の処理から、時間的な動的パターンを扱う「音声・聴覚認知」への拡張は、脳型 AI のエネルギー効率を実用に耐えうるシステムへと飛躍させるための重要なマイルストーンである。本研究では、人間の聴覚音声処理階層（蝸牛、聴神経、聴覚野、言語野）を統合的に模倣し、高効率かつ高精度な脳型音声認識システムを構築することを目的とする。

3 関連研究

3.1 先行研究：Difference Bi-Predictive Coding (Diff-bPC)

筆者らは、識別（ボトムアップ）と生成（トップダウン）を同一のエネルギー関数で両立する「Difference Bi-Predictive Coding (Diff-bPC)」を提案し、SNN への実装を行ってきた（卒業論文, 2026; final_report_gemini.pdf）。このモデルでは、3 値スパイク（ $\{-1, 0, 1\}$ ）をベースとした Difference Predictive Coding (DiffPC) を拡張し、トップダウン生成的予測誤差 ϵ_l^{gen} とボトムアップ識別的予測誤差 ϵ_l^{disc} を同時に最小化するエネルギー関数 E を定義した。

$$E(x, W, V) = \sum_{l=1}^{L-1} \frac{\alpha_{\text{gen}}}{2} \|x_l - W_{l+1}f(x_{l+1})\|_2^2 + \sum_{l=2}^L \frac{\alpha_{\text{disc}}}{2} \|x_l - V_{l-1}f(x_{l-1})\|_2^2 \quad (1)$$

ここで、 x_l は第 l 層のニューロン活動、 W は生成（トップダウン）重み、 V は識別（ボトムアップ）重みであり、 f は活性化関数である。この局所的な予測誤差更新式と動的閾値 T_θ の巡回スケジューリングにより、MNIST 手書き数字データセットにおいて 93.84% の分類精度を達成しつつ、従来の非 SNN 双方向モデル（bPC）と比較して層間通信量を大幅に削減することに成功した。しかし、スパイク化に伴う情報の欠落から、識別精度および画像生成画像品質において非 SNN モデルと比較して課題が残されており、このアプローチをさらにロバストで時間情報処理に適したシステムへと拡張する必要性が生じていた。

3.2 SNN 音声認識の動向

音声は本質的に時間変化するダイナミックな信号であり、スパイクの時間発火ダイナミクスをネイティブに扱える SNN との親和性が極めて高い（Baek & Lee, 2024）。これまでの SNN を用いた音声認識研究は、大きく二つのアプローチに大別される（Park et al., 2024）。

第一のアプローチは、生物学的妥当性の極めて高いローカル学習則である「スパイクタイミング依存可塑性（STDP）」を用いた無教師特徴抽出である。Tavanaei & Maida (2017b) は、STDP を用いて音声信号から「Spike Signatures」を自律抽出する多層 SNN を構築した。また、Dong et al. (2018) は、畳み込み SNN に STDP を組み合わせ、TIDIGITS や TIMIT などのデータセットにおいて無教師学習でありながら高い分類性能を達成できることを実証した。しかし、STDP 単独による学習は、より複雑で高次元な時間的コンテキスト（時系列構造）の獲得において表現力不足となる課題を抱えている。

第二のアプローチは、サロゲート勾配（Surrogate Gradient）を用いた「時間方向の誤差逆伝播（BPTT）」によるエンドツーエンドの教師あり学習である。Martinelli et al. (2020) は、回帰型 SNN（RSNN）に対してサロゲート勾配 BPTT を適用することで、低消費電力な音声活動検出（VAD）を高い精度で実現した。さ

らに、Wu et al. (2018a, 2020) らは、時間遅延 (axonal delay) や時定数のダイナミクスがロバストな音声自動音声認識 (ASR) に寄与することを大規模語彙タスクにおいて示している。しかし、BPTT は大域的な誤差情報のタイムトラベルと展開による膨大なメモリ保持を必要とするため、生物学的妥当性を大きく欠き、低消費電力なエッジハードウェアへの実装時における大きなボトルネックとなる。

3.3 生体模倣聴覚符号化 (BAE)

音声波形から高効率なスパイク列への変換は、SNN の能力を引き出すための最も重要な要素の一つである。Pan et al. (2020) が提案した「Biologically plausible Auditory Encoding (BAE)」は、従来の単純なレートコーディング (Rate Coding) や時間・レイテンシコーディングの限界を克服する符号化法である。BAE は、人間の内耳 (蝸牛) のフィルタリング、インナーヘアセルの変換特性に加え、音響心理学的な「マスキング効果 (同時マスキングおよび時間マスキング)」を統合的にモデル化している。これにより、人間が知覚不可能な (聴こえない) 微小な音声帯域や、大振幅音の直後に生じる時間的減衰領域を「無効なデータ (冗長性)」として完全に除去し、スパイクを極めてスパース (疎) に抑えつつも、高い知覚品質と高い分類精度を維持できることが証明されている。

3.4 Whisper モデルと脳活動の整合性 (脳科学的妥当性)

近年、最新の計算論的神経科学において、深層マルチモーダル音声言語モデルと生体脳における情報処理階層の「機能的整合性 (アライメント)」が実験的に証明された (Goldstein et al., 2025)。

この研究では、患者が自然なストーリー (Podcast) を聴取している際の頭蓋内脳電図 (ECoG) データと、音声認識モデルである「Whisper」の内部表現 (エンコーダおよびデコーダの中間レイヤ) を線形マッピングを用いて対比した。その結果、Whisper の「音声エンコーダ (Speech Embeddings)」の活動は、音声を一次処理する人間の「上側頭回 (STG: 聴覚野)」の神経ダイナミクスと驚異的な精度で整合し、一方で「テキストデコーダ (Language Embeddings)」の表現は、より高次の文脈処理を行う「下頭頂葉・下前頭回 (IFG: ブローカ野など)」とアライメントすることが実証された。

この知見は、人間の聴覚・言語脳を計算機上に再構築する上で、「音響符号化 (内耳・蝸牛) → 時間予測自律学習 (聴覚野) → 線形解読・音素列抽出 (言語野・言語デコーダ)」という一連の階層構造および情報流が、単なる工学的妥当性のみならず、確固たる「脳科学的妥当性」に裏打ちされていることを強く示している。

4 提案手法 (聴覚音声認識の脳型 SNN システム)

本研究で提案するシステムは、人間の耳 (蝸牛) から脳の一次・二次聴覚野 (STG)、そして音素列を認識する言語野への一連の情報流を忠実に模倣した **4 つのステージ** から構成される。全体構成を図 1 に示す。

4.1 Stage 1: 音声のスパイク化 (入力層・耳)

入力された連続音声波形は、MATLAB 上に実装した生体模倣聴覚符号化 (BAE) アルゴリズム (Pan et al., 2020) によって、**620 次元のスパイク列** (20 周波数チャンネル × 31 閾値ニューロン) へと変換される。処理プロセスは以下のステップから構成される。

1. コクリア・フィルタバンク (内耳) :

【入力音声波形】

|

[Stage 1] 生体模倣聴覚符号化 (BAE frontend)

| (CQT フィルタ、同時・時間マスキング効果、閾値コーディング)

v

【620 次元スパイク列 (Spike-TIMIT / Spike-Podcast)】

|

[Stage 2] Predictive E-prop RSNN 自律学習 (隠れ層 = 聴覚野 STG)

| (自己教師あり予測予測誤差最小化、ローカル学習則 Eligibility Trace)

v

【300 次元 SNN 状態ダイナミクス】

|

[Stage 3] ラスタプロット可視化・PCA 幾何学的解析・脳活動 (ECoG) との機能的相関分析

|

[Stage 4] 線形デコーダ (出力層 = 言語野)

| (音素ラベルマッピング、CTC 損失、End-to-End 音素認識)

v

【認識された音素列】

図 1 提案する脳型聴覚音声認識システムの全体像

入力音声信号 x に対し、中心周波数が等価矩形帯域 (ERB) スケールまたは CQT (Constant Q Transform) に基づき対数配置された $K = 20$ 個のフィルタを用いて、時間領域での畳み込みを並列実行し、各周波数チャンネル subband $y_k(t)$ を抽出する。

2. 対数フレームエネルギー算出:

30 ms の窓長、15 ms のスライド幅でサブバンド信号をフレーム化し、以下の対数フレームエネルギー $e_k(j)$ を計算し、2 次元の時間-周波数スペクトログラム $S_{K \times N}$ を得る。

$$e_k(j) = 10 \log_{10} \left(\sum_{q=1}^L x_{kq}^2 \right) \quad (2)$$

3. 音響心理マスキング処理 (冗長性のカット) :

周波数軸方向の同時マスキング閾値 $T_a(f)$ (式 3) と、時間軸方向の時間マスキング閾値 $y(n)$ (式 4) を計算し、その最大値を全体マスキング閾値 m_{ij} とする。

$$T_a(f) = 3.64 \left(\frac{f}{1000} \right)^{-0.8} - 6.5e^{-0.6 \left(\frac{f}{1000} - 3.3 \right)^2} + 0.001 \left(\frac{f}{1000} \right)^4 \quad (3)$$

$$y(n) = c^n \cdot p_1 \quad (4)$$

ここで、 c は指数減衰定数、 p_1 は直前のローカルピークにおけるスペクトルパワー強度である。全体の 2 次元マスキングマップ $\Phi_{K \times N}(\phi_{ij})$ は次式で二値化され、スペクトログラム S にハダマル積として適用

される。

$$\phi_{ij} = \begin{cases} 1 & \text{if } s_{ij} \geq m_{ij} \\ 0 & \text{if } s_{ij} < m_{ij} \end{cases} \quad (5)$$

4. 閾値コーディング (Threshold-crossing) :

マスクングを通過したフレームエネルギーに対し、31 個の均等に配置されたエネルギー閾値 T_θ を超える瞬間にスパイク (発火事象) を発生させる。これにより、エネルギーの動的な「変動軌跡」のみを追従した極めてスパースで情報量の豊富な 620 次元のスパイク列 $P_{\text{mask}} = P_{K \times N} \circ \Phi_{K \times N}$ が生成される。

4.2 Stage 2: Predictive E-prop RSNN の自律学習 (隠れ層・聴覚野 STG)

生成された 620 次元の入力スパイクは、適応閾値を持つ ALIF (Adaptive Leaky Integrate-and-Fire) ニューロンおよび通常の LIF ニューロンから構成される回帰型スパイクニューラルネットワーク (RSNN、ニューロン数: 300 個) に供給される。

通常、RSNN の学習には時間展開が必要な大域的な BPTT が使用されるが、本研究では生物学的に妥当なオンライン学習則である **E-prop (Eligibility Propagation)** (Bellec et al., 2020) を採用する。学習タスクには正解ラベル (音素) を用いず、現在のニューロン活動から「次のミリ秒の入力スパイク変動」を予測する **自己教師あり前向き予測 (Predictive SSL)** を課す。

各ニューロンの膜電位 $v_j(t)$ および閾値 $A_j(t)$ のダイナミクスは以下のように表される。

$$v_j(t+1) = \alpha v_j(t) + \sum_i w_{ji}^{\text{in}} x_i(t) + \sum_i w_{ji}^{\text{rec}} z_i(t) - z_j(t) v_{\text{th}} \quad (6)$$

E-prop では、重みの更新勾配 Δw_{ji} を、各ニューロンの局所的な情報である「適格性トレース (Eligibility Trace)」 $e_{ji}(t)$ と、トップダウンにフィードバックされる「学習シグナル (Learning Signal)」 $L_j(t)$ の積のオンライン累積として算出する。

$$\Delta w_{ji} = \eta \sum_t L_j(t) \cdot e_{ji}(t) \quad (7)$$

これにより、将来の入力を前向きに予測するプロセス (Predictive SNN) において、時間方向の逆伝播なしに RSNN の再帰シナプス重み W^{rec} が自律学習 (自己組織化) される。

4.3 Stage 3: SNN 活動解析および ECoG データとの相関・アライメント分析 (可視化・分析)

学習された LIF/ALIF ニューロンによる RSNN の内部ダイナミクスを分析し、生物学的な妥当性を検証するために、本研究では単純な線形回帰マッピングに依存しない多角的な分析を行う。

1. ラスタープロット (Raster Plot):

300 個のニューロンの発火パターンを時間軸に対して並べ、母音・子音や各音素、および音響インパルスに対する協調発火動態、ALIF による長い時間依存性の保持能力を視覚的に評価する。

2. 潜在空間の幾何学的軌跡解析 (Trajectory Analysis):

RSNN の隠れ状態の平滑化出力 $\bar{z}_t \in \mathbb{R}^{300}$ を、PCA (主成分分析) や t-SNE によって 2 次元・3D へと圧縮投影する。音素カテゴリごとに内部状態空間の軌跡 (Trajectory) が明確にクラスター化 (Clustering) され、音素の境界を明瞭に区別してダイナミクスが遷移していく様子を解析する。

3. 頭蓋内脳電図 (ECoG) データとの機能的・表現的整合性 (アライメント) 分析:

OpenNeuro で公開されている 30 分間の Podcast 聴取時の 「"Podcast" ECoG dataset」を用いて、本モデルの「生物学的妥当性」を多角的に評価する。脳データへの恣意的なフィッティング (回帰重みの学習) を排除し、モデルが持つ表現トポロジーやスパイクの時間動態そのものをダイレクトに比較するため、以下の 4 つのアプローチを検討・適用する。

- **A) 線形エンコーディングモデル (Ridge Regression) [従来のフィッティングアプローチ]:**

ECoG 実験で用いられた同一の Podcast 音響波形を本モデルに入力し、Stage 2 で得られた RSNN の隠れ層ダイナミクス $\bar{z}_t$ から、患者の一次聴覚野 (STG など) における High-gamma 帯域 (75-200Hz) の時間変動脳活動波形 $r(t)$ を予測する Ridge 回帰モデルを構築する (図 2)。

$$\hat{r}(t) = \beta^\top \bar{z}_t \quad (8)$$

未知のテスト音声に対する、モデル予測値 $\hat{r}(t)$ と実際の脳活動 $r(t)$ のピアソン相関 (Pearson's r) を計算する。

【Podcast 音響波形】

|

【本提案モデル】

|

(隠れ層の表現 $\bar{z}_t$) ----> [線形マッピング (Ridge 回帰)] ----> [予測された脳活動 $\hat{r}(t)$]

| (ピアソン相

関 r)

v

【実際の ECoG 活動 $r(t)$ 】

図 2 線形エンコーディングモデルを用いたモデルと脳活動の相関分析

- **B) 表現類似性解析 (Representational Similarity Analysis: RSA) [パラメータフリーの幾何学的アライメント]:**

モデルが獲得した「音 (刺激) の類似度関係 (幾何学的トポロジー)」と、人間の脳が感じている「類似度関係」がどれだけ一致しているかをダイレクトに比較する (Kriegeskorte et al., 2008)。

具体的には、同一の音声刺激セット (代表的な単語や母音音素など) に対する SNN の平滑化活動 $\bar{z}_t$ から、刺激ペア間のコサイン距離や相関距離を計算し、 $N \times N$ のモデル表現選別行列 (RDM_{SNN}: Representational Distance Matrix) を作成する。同様に、同一刺激に対する ECoG 電極群 (STG など) の High-gamma 応答から $N \times N$ の RDM_{ECoG} を構築する。この 2 つの RDM の下三角成分同士の間関係数を直接算出する (図 3)。これにより、回帰のようなマッピングの重みを学習させる必要が一切なく、表現の類似性をダイレクトに比較可能である。

$$\text{RSA-alignment} = \text{corr}(\text{vech}(\text{RDM}_{\text{SNN}}), \text{vech}(\text{RDM}_{\text{ECoG}})) \quad (9)$$

- **C) Centered Kernel Alignment (CKA) [高次元表現空間のダイレクトアライメント]:**

SNN の時系列活動行列 $X \in \mathbb{R}^{T \times 300}$ と、ECoG の活動行列 $Y \in \mathbb{R}^{T \times C}$ (C は電極数) について、サンプルの時間スケールを合わせた状態で、表現類似性を線形または非線形カーネルを用いて 0 から 1 の




図3 表現類似性解析 (RSA) による脳とモデルのトポロジー的直接アライメント評価

値でダイレクトに算出する (Kornblith et al., 2019)。これにより、次元数が全く異なる隠れ層と皮質表現のダイナミクスの整合性を、重みの学習を挟むことなく定量化できる。

- **D) Spike-Field Coherence (SFC) & Spike-Triggered Average (STA) [スパイク-場電位レベルの時系列同期解析]:**

SNN が持つ「離散パルス発火 (スパイク)」という特性を活かし、ECoG という連続場電位 (LFP に相当) との時系列・周波数領域での直接的な同期動態を評価する (Fries, 2005)。

SNN の特定のニューロンがスパイクを発火したタイミング (時刻 t_{spike}) の前後数ミリ秒における ECoG の High-gamma 振幅や、特定の周波数帯 (例えば低周波オシレーションの位相) を抽出し、それらを加算平均して「スパイク誘発電位 (STA: Spike-Triggered Average)」を構築する。STA に明瞭な時間的波形が浮かび上がる、あるいはスパイク発火タイミングと ECoG のオシレーション位相に強い位相コヒーレンス (Spike-Field Coherence: SFC) が確認される場合、SNN の個々のニューロン発火が、実際の生体脳のニューロン集団の同期活動とミリ秒レベルで直接同期・カップリングしていることをダイレクトに証明できる。

4.4 Stage 4: 線形デコーダによる音素分類 (出力層・言語野)

自律学習した RSNN の再帰重み W^{rec} を完全に固定 (Freeze) し、その上にシンプルな 1 層の**線形全結合層 (Linear Readout Decoder)** を追加して音素分類を実行する。

- **目的:**

線形デコーダという極めて表現力の限定された分類器で高精度な音素抽出 (分類) が達成できること自体が、前段の Predictive E-prop RSNN の内部状態空間において、各音素情報が「線形分離可能な形」で高度に自己組織化 (整理) されていることを示す。

- **学習手法:**

TIMIT データセットの各音声フレームに紐付けられた音素ラベルアライメント (.phn) を正解 (教師) 信号とし、音素クロスエントロピー損失または CTC (Connectionist Temporal Classification) 損失関数を用いてデコーダの出力接続重み W^{out} のみを高速に教師あり学習させる。これにより、End-to-End の音素

列出力システムが完成する。

5 現在の状況と今後の実験計画

5.1 現在までの進捗状況

現在、提案システムにおける開発のフェーズは以下の状況にある。

1. Stage 1: 音声のスパイク化 (BAE フロントエンド) の MATLAB 実装完了 (進捗 100%) :

MATLAB コード (`encode_single_wav.m`) による BAE ツール群の実装と、入力連続波形から 620 次元のスパイク列を生成するエンコーダプログラムが完成している。テスト音声 (TIMIT、Podcast) を適用し、同時マスキング $Ta(f)$ および時間マスキングの計算、および閾値判定により、音声の情報ダイナミクスを的確に保持したまま、発火率を約 50% 削減した極めてスパースなスパイク列が正常に出力されることを波形・ラスタプロットにて確認・検証済みである。

2. Stage 2: Predictive E-prop RSNN の自律学習の再現検証 (進捗 40%) :

Network.py 上の PredictiveEPropRSNN を定義し、E-prop 自律学習アルゴリズム (Bellec et al., 2020) の再現・検証コードを構築中である。現在は、公開されている既存文献のベンチマーク実験 (合成信号や簡易時系列タスク) を用いて、大域的 BPTT を用いない適格性トレースによるオンライン重み更新が意図通り安定して収束するかどうかの、再現検証を行っている段階である。

5.2 今後の実験計画

今後の中間・最終報告に向け、以下のステップで実証評価を進める。

● ステップ 1: Stage 1 と Stage 2 の接続 (2026 年 9 月中旬まで) :

構築した BAE エンコーダで変換した TIMIT データおよび Podcast 音声のスパイク列を、Predictive E-prop RSNN の入力としてパイプライン接続する。高次元 (620 次元) スパイク列の時間変動予測タスクにおいて、自律学習 (RSNN 再帰重みの更新) を動作させ、膜電位や適格性トレースの安定性をチューニングする。

● ステップ 2: 内部ダイナミクス可視化とクラスタリング分析 (2026 年 9 月下旬まで) :

学習済みモデルの隠れ層発火からラスタプロットを出力する。また、各フレームでの 300 次元状態を PCA/t-SNE によって低次元展開し、状態軌跡が母音 (/a/, /i/, /u/等) や子音といった音響音素カテゴリごとに空間上でどのように幾何学的なクラスターを形成するか、その自己組織化能力を視覚的に評価する。

● ステップ 3: ECoG データとの脳活動機能的整合性・直接アライメント評価 (2026 年 10 月中旬まで) :

OpenNeuro の「Podcast」ECoG dataset」を活用し、図 2 に示す線形エンコーディングモデル (Ridge 回帰) に加え、パラメータフィッティングを必要としない表現類似性解析 (RSA)、Centered Kernel Alignment (CKA)、および Spike-Field Coherence (SFC) や Spike-Triggered Average (STA) を用いたスパイク-LFP 直接同期解析を実装する。本モデルの隠れ層発火およびダイナミクスと、実被験者の一次聴覚野 (STG) や言語エリア (IFG など) における High-gamma 神経活動の間のアライメントスコアを、トポロジー幾何・時系列同期・予測精度の多角的な視点から算出し、生物学的な妥当性を学術的に徹底検証する。

● ステップ 4: 線形デコーダ接続による音声認識性能の測定 (2026 年 10 月下旬まで) :

TIMIT データセットを用いて線形 Readout デコーダを学習させ、フレームごとの音素分類精度、および CTC を用いた音素エラー率 (PER: Phone Error Rate) を算出する。同時に、計算中の累積スパイク発火数をカウントすることで、従来の ANN と比較した際のモデルの「極めて高いエネルギー効率 (スパース通信効果)」を定量化して検証する。

6 まとめ

本研究は、現代 AI の課題であるエネルギー非効率性を克服するために、脳の低電力動作原理 (SNN + 予測符号化) を音声認知システムへと拡張する先進的な試みである。

これまでに、耳・蝸牛の精緻な符号化と心理音響マスキングを模倣した「Stage 1 (BAE)」の開発を完了し、現在、聴覚野に相当する自律型予測学習システム「Stage 2 (Predictive E-prop RSNN)」の再現および数理的な調整を進めている。

今後は、Stage 1 と 2 の統合を進めるとともに、OpenNeuro 公開の「Podcast」 ECoG 脳信号データセットとの機能的整合性分析 (脳活動アライメント評価) を行い、本提案モデルが脳の音声・言語処理プロセスをどの程度忠実に自己組織化できているかを検証する。この結果は、学術的な計算論的神経科学への貢献だけでなく、次世代の省電力ニューロモルフィックエッジハードウェア向けの音声認識・聴覚センサーフロントエンド技術としての応用展開が期待される。

参考文献

- [1] Kornblith, S., Norouzi, M., Lee, H., & Hinton, G. (2019). Similarity of neural network representations revisited. In *International Conference on Machine Learning* (pp. 3519-3529). PMLR.
- [2] Kriegeskorte, N., Mur, M., & Bandettini, P. A. (2008). Representational similarity analysis: connecting the branches of systems neuroscience. *Frontiers in Systems Neuroscience*, 2, 4.
- [3] Fries, P. (2005). A mechanism for cognitive dynamics: neuronal communication through coherence. *Trends in Cognitive Sciences*, 9(10), 474-480.
- [4] Baek, S., & Lee, J. (2024). Snn and sound: a comprehensive review of spiking neural networks in sound. *Biomedical Engineering Letters*, 14, 981 – 991.
- [5] Bellec, G., Sala, D., Subramoney, A., Legenstein, R., & Maass, W. (2020). A solution to the learning dilemma for recurrent networks of spiking neurons. *Nature Communications*, 11, 3625.
- [6] Dong, M., Huang, X., & Xu, B. (2018). Unsupervised speech recognition through spike-timing-dependent plasticity in a convolutional spiking neural network. *PLoS ONE*, 13(11), e0204596.
- [7] Goldstein, A., Wang, H., Niekerken, L., Schain, M., Zada, Z., Aubrey, B., ... & Hasson, U. (2025). A unified acoustic-to-speech-to-language embedding space captures the neural basis of natural language processing in everyday conversations. *Nature Human Behaviour*, 10.1038/s41562-025-02105-9.
- [8] Herculano-Houzel, S. (2011). Scaling of brain metabolism with a fixed energy budget per neuron: Implications for human brain evolution. *Frontiers in Human Neuroscience*, 5, 110.
- [9] Lake, B. M., Ullman, T. D., Tenenbaum, J. B., & Gershman, S. J. (2017). Building machines that learn and think like people. *Behavioral and Brain Sciences*, 40, e253.

- [10] Martinelli, F., Dellaferrera, G., Mainar, P., & Cernak, M. (2020). Spiking neural networks trained with backpropagation for low power neuromorphic implementation of voice activity detection. In *ICASSP 2020*, 8544 – 8548.
- [11] McCloskey, M., & Cohen, N. J. (1989). Catastrophic interference in connectionist networks: The sequential learning problem. *Psychology of Learning and Motivation*, 24, 109 – 165.
- [12] Millidge, B., Seth, A., & Buckley, C. L. (2021). Predictive coding: a theoretical and experimental review. *arXiv preprint arXiv:2107.12979*.
- [13] Pan, Z., Chua, Y., Wu, J., Zhang, M., Li, H., & Ambikairajah, E. (2020). An efficient and perceptually motivated auditory neural encoding and decoding algorithm for spiking neural networks. *Frontiers in Neuroscience*, 13, 1420.
- [14] Patterson, D., Gonzalez, J., Le, Q., Liang, C., Munguia, L.-H., Rothchild, D., ... & Dean, J. (2021). Carbon emissions and large neural network training. *arXiv preprint arXiv:2104.10350*.
- [15] Srinivasan, M. V., Laughlin, S. B., and Dubs, A. (1982). Predictive coding: a fresh view of inhibition in the retina. *Proceedings of the Royal Society of London. Series B. Biological Sciences*, 216, 427 – 459.
- [16] Tavanaei, A., & Maida, A. S. (2017b). A spiking network that learns to extract spike signatures from speech signals. *Neurocomputing*, 240, 191 – 199.
- [17] van de Ven, G. M., Siegelmann, H. T., & Tolia, A. S. (2024). Brain-inspired continually learning neural networks. *Nature Reviews Neuroscience*, 25, 101 – 118.
- [18] Wu, J., Chua, Y., and Li, H. (2018a). A biologically plausible speech recognition framework based on spiking neural networks. In *IJCNN 2018*, 1 – 8.
- [19] Wu, J., Yilmaz, E., Zhang, M., Li, H., and Tan, K. C. (2020). Deep spiking neural networks for large vocabulary automatic speech recognition. *Frontiers in Neuroscience*, 14, 199.