

1 要旨

近年、大規模言語モデル（LLM）に代表される深層生成 AI は目覚ましい性能を示しているものの、その運用に必要な膨大な計算資源とデータ量、および「破滅的忘却」といった脳科学的な乖離が課題となっている。本研究では、脳の低電力インメモリ計算およびイベント駆動型スパース処理を模倣するスパイキングニューラルネットワーク（SNN）と、自己組織化的なオンライン学習を可能にする「予測符号化理論（Predictive Coding）」を統合した、新しい音声・聴覚認知システムの構築を目指す。

筆者の先行研究では、手書き数字画像タスクにおいて双方向予測符号化モデル（Diff-bPC）の実装と評価を行ってきた。本研究は、これを時間軸方向の動的なパターン処理が必要とされる「音声認識」タスクへと拡張するものである。

具体的には、人間の耳から聴覚野、言語野にいたる情報処理流を模倣した 4 つのステージ（Stage 1~4）からなる脳型音声認識システムを構築する。現在までに、生体模倣聴覚符号化（BAE）を用いた音声のスパイク化（Stage 1）の実装を完了し、時間予測に基づく自律学習則である Predictive E-prop（Stage 2）の再現・調整を行っている。本稿では、各パーツの詳細な構成、現在までの進捗状況、および OpenNeuro 公開の "Podcast" ECoG (electrocorticography, 皮質脳波) データセットを用いた脳機能機能的アライメント（相関解析）の評価計画について報告する。

2 背景と目的

現在、主流となっている人工知能（AI）やそれに含まれる大規模言語モデル（LLM）は、特定のタスクや推論において人間を凌駕する性能に到達している。しかし、その成功は数ギガワット級の巨大な計算インフラと膨大な炭素排出を伴うもの [34] であり、極めて高い計算資源コストとエネルギー非効率性に直面している。また、これらのモデルは数兆トークンに及ぶ莫大なデータから表現を学習する一方、生体脳のように限られたサンプルから効率的に汎化（Few-shot 学習）する柔軟性を欠いている [20]。さらに、新しい環境や追加のタスクに適応させようとすると、既存の学習済み表現が破壊的に上書きされる「破滅的忘却」[25, 39] が深刻な問題となっている。

これに対し、人間の脳は約 20W という極めて微小な電力で動作し、リアルタイムに外界の複雑なマルチモーダル情報を認識・処理する [15]。この圧倒的なエネルギー効率の源泉は、フォン・ノイマン・ボトルネックを克服したシナプス結合による「インメモリ計算」と、必要な情報が到来したときにのみスパイクを介して非同期的に通信・計算を行う「イベント駆動型スパース処理」にある。

この生体脳の卓越した特性を模倣するために、第三世代のニューラルネットワークであるスパイキングニューラルネットワーク（SNN）が近年活発に研究されている。SNN は、時間情報を伴う $\{0, 1\}$ （あるいは極性を持つ $\{-1, 0, 1\}$ ）のパルス状信号である「スパイク」で通信を行う。これにより計算負荷を飛躍的に削減できるが、微分不可能という数学的障壁のため、大域的な「誤差逆伝播法（Backpropagation）」の直接的な適用が極めて困難である。ただし、誤差逆伝播法はネットワーク全体で詳細な大域的誤差情報を即座に共有する必要があり、生体脳のシナプスが局所的な（ローカルな）情報のみで自己組織的に学習している事実（生物学的妥当性）とはミスマッチしているため、SNN にそれを導入するかは議論の余地がある。

この課題を解決する有力なアプローチが、脳の認知理論である「予測符号化理論（Predictive Coding）」[26, 38] である。予測符号化は、上位層からのトップダウンの「予測」と、感覚入力との「予測誤差」を直近の層間で

局所的に最小化することで、大域的な誤差共有なしに表現学習を実現する。

本研究は、筆者の先行研究である画像ベースの双方向予測符号化 SNN 「Difference Bi-Predictive Coding (Diff-bPC)」 [41] の知見を基盤とする。静的な空間パターン（画像）の処理から、時間的な動的パターンを扱う「音声・聴覚認知」への拡張は、脳型 AI のエネルギー効率を実用に耐えうるシステムへと飛躍させるための重要なマイルストーンである。本研究では、人間の聴覚音声処理階層（蝸牛、聴神経、聴覚野、言語野）を統合的に模倣し、高効率かつ高精度な脳型音声認識システムを構築することを目的とする。

3 関連研究

3.1 先行研究：Difference Bi-Predictive Coding (Diff-bPC)

筆者は、識別（ボトムアップ）と生成（トップダウン）を同時に扱う「Difference Bi-Predictive Coding (Diff-bPC)」 [41] を提案し、SNN への実装を行ってきた。このモデルは、3 値スパイク（ $\{-1, 0, 1\}$ ）をベースとした「Difference Predictive Coding」 (DiffPC) [17] に、識別と生成を同一のエネルギー関数に組み込むことで、両方の予測誤差の最小化を両立した「Bidirectional Predictive Coding」 (bPC) [30] の双方向性を取り入れたものである。学習の基盤となるエネルギー関数には、トップダウン生成的予測誤差 ϵ_l^{gen} とボトムアップ識別的予測誤差 ϵ_l^{disc} を同時に最小化する bPC で定義されたものを採用した。

$$E(x, W, V) = \sum_{l=1}^{L-1} \frac{\alpha_{\text{gen}}}{2} \|x_l - W_{l+1}f(x_{l+1})\|_2^2 + \sum_{l=2}^L \frac{\alpha_{\text{disc}}}{2} \|x_l - V_{l-1}f(x_{l-1})\|_2^2 \quad (1)$$

ここで、 x_l は第 l 層 of ニューロン活動、 W は生成（トップダウン）重み、 V は識別（ボトムアップ）重みであり、 f は活性化関数である。この局所的な予測誤差更新式と動的閾値 T_θ の巡回スケジューリングにより、MNIST 手書き数字データセットにおいて 93.84% の分類精度を達成しつつ、従来の非 SNN 双方向モデル (bPC) と比較して層間通信量を大幅に削減することに成功した。しかし、スパイク化に伴う情報の欠落から、識別精度および画像生成画像品質において非 SNN モデルと比較して課題が残されており、このアプローチをさらにロバストで時間情報処理に適したシステムへと拡張する必要性が生じていた。

3.2 SNN 音声認識の動向

本セクションでは、レビュー論文 [2, 33] を基に音声処理向け SNN における基盤技術である「スパイク・エンコーディング」と、ネットワークを最適化するための「学習則」の最新の研究動向について整理し、本研究における提案手法の位置付けを明確にする。

音声波形のような連続的なアナログ時系列データを SNN へ適用する上で、まず必要となるのが入力信号を離散的なスパイク列に変換するスパイク・エンコーディング技術である [33]。この符号化手法は、主にレートコーディング（頻度符号化）とテンポラルコーディング（時間符号化）の 2 つのアプローチに大別される。レートコーディングは、入力信号の強度を単位時間あたりのスパイク発火頻度にマッピングする直感的な手法であり [13]、一定の時間窓内で生成されたスパイク総数に注目するカウントレート [1] や、スパイク間の時間的近接度に着目した密度レート [11]、さらには複数のニューロンの活動パターンとして多次元情報を捉えるポピュレーションレート [9] などが挙げられる。これに対し、スパイクが発生する精密な時間（タイミングや間隔）そのものに情報を保持させるテンポラルコーディングは、時間分解能に優れたより生物学的妥当性の高い手法である [35]。代表的なものとして、刺激強度を最初のスパイクが発生するまでの遅延時間に反比例させる

Time-to-First-Spike (TTFS) や、連続するスパイク間の時間間隔を利用する Interspike Interval (ISI) [31] が存在する。また、入力信号の振幅変化が一定の閾値を超えた場合にのみ発火させる Send-on-Delta (SOD) は、冗長なデータの送信を劇的に抑制し、電力効率を飛躍的に高めるイベント駆動型アプローチとして注目を集めている [27]。近年では、これらのアプローチを組み合わせたハイブリッド符号化モデル [6] や、人間の聴覚末梢系のダイナミクスを反映した聴覚フィルタバンクに基づく符号化手法も数多く提案されている。

SNN の機能性を高め、複雑なタスクへの適応を可能にする第 2 のコア技術が、スパイクの不連続かつ非微分的な性質を克服するための学習則である。現在の学習則は主に、生物学的に妥当な学習、勾配ベースの直接学習、および ANN からの変換技術 (ANN-to-SNN 変換) の 3 つのアプローチに沿って発展を遂げている。生物学的な学習則の代表例であるスパイクタイミング依存可塑性 (Spike-Timing-Dependent Plasticity: STDP) は、前後のニューロンが発火するミリ秒単位の時間差に基づきシナプス荷重を自己組織的に更新する規則である [4]。これは教師なしでの局所的な特徴抽出に極めて適しており、音声認識システムの前処理層や自動特徴抽出器として応用されている [8, 24]。一方、近年の深層 SNN の認識精度を劇的に向上させたのが勾配ベースの直接学習手法である。微分不可能なスパイク発生関数に対して逆伝播時に滑らかな近似関数を代入するサロゲート勾配 (Surrogate Gradient) 法の登場により [28]、時系列の誤差逆伝播法 (Backpropagation Through Time: BPTT) [37, 40] の適用が可能となった。これにより、音声コマンド認識、音声区間検出 (VAD) [23] などのタスクにおいて、高い認識精度を持つ多層 SNN の直接学習 [21] が実現されている。また、別のアプローチとして、既存の高精度な学習済み ANN のシナプス重みとバイアス値を、閾値やリセット機構を調整しながら SNN へと写像する ANN-to-SNN 変換技術 [5, 7] も広く実用されており、変換時の情報損失を最小限に抑えるソフトリセット (膜電位の調整) 機構 [14] などの技術も研究されている。

このように、SNN を用いた音声処理研究は、エンコーディングから学習則に至るまで多角的なアプローチによって進化を遂げており、近年では音源定位の高度化 [16] や、音響情報と視覚情報をシナプスレベルで統合するマルチモーダル SNN への展開 [22, 36] といった応用範囲の広がりを見せている。しかし、実用的な音声認識タスクにおいて高精度かつ真に低遅延なシステムを実装するためには、依然としていくつかの共通課題が残されている。具体的には、勾配ベースの学習 (BPTT) における莫大な時系列計算負荷、音声の音響ダイナミクスを最も損なわずにスパイク情報へと集約できる最適なエンコーディングアルゴリズムの未確立、およびニューロモフィックチップへ展開する際のエネルギー・遅延効率のさらなる最適化などが挙げられる。本研究で提案する手法は、これら既存の動向と課題を見据えた上で、特定の課題に対するブレイクスルーとなるアプローチを提供するものである。

3.3 生体模倣聴覚符号化 (BAE)

音声波形から高効率なスパイク列への変換は、SNN の能力を引き出すための最も重要な要素の一つである。Pan ら [32] が提案した「Biologically plausible Auditory Encoding (BAE)」は、従来の単純なレートコーディング (Rate Coding) や時間・レイテンシコーディングの限界を克服する符号化法である。BAE は、人間の内耳 (蝸牛) のフィルタリング、インナーヘアセルの変換特性に加え、音響心理学的な「マスキング効果 (同時マスキングおよび時間マスキング)」を統合的にモデル化している。これにより、人間が知覚不可能な (聴こえない) 微小な音声帯域や、大振幅音の直後に生じる時間的減衰領域を「無効なデータ (冗長性)」として完全に除去し、スパイクを極めてスパース (疎) に抑えつつも、高い知覚品質と高い分類精度を維持できることが証明されている。

3.4 Whisper モデルと脳活動の整合性

近年の計算論的神経科学では、深層マルチモーダル音声言語モデルと生体脳における言語処理表現の間に、予測可能な機能的整合性（アライメント）が存在することが実験的に示されている [12].

Goldstein らは、治療抵抗性てんかんのため頭蓋内電極を留置していた患者 4 名を対象に、入院中に家族、友人、医師、病院スタッフらと交わした自然な日常会話を記録した。患者が自由に会話している間の ECoG と音声 を 24 時間体制で収集し、発話産出および音声理解を合わせた約 100 時間、約 52 万語のデータを解析した。

研究者らは、音声認識モデル Whisper のエンコーダおよびデコーダから、音響・音声・言語に対応する埋め込み表現を抽出し、それらから各 ECoG 電極の神経活動を線形エンコーディングモデルによって予測した。

その結果、Whisper の音声埋め込みは、上側頭回（STG）や前中心回・後中心回などの音声知覚・発話関連の感覚運動領域の活動を相対的によく説明し、言語埋め込みは、下前頭回（IFG）、角回（AG）、後部中側頭回（pMTG）などの高次言語関連領域の活動を相対的によく説明した。ただし、これらの領域は完全に分離された機能モジュールではなく、音声表現と言語表現の双方が広範な領域の活動を説明する混合的な表現も確認された。

時間的には、発話産出において、IFG における言語埋め込みの予測ピークが、感覚運動領域における音声埋め込みの予測ピークに先行した。一方、音声理解では、STG における音声埋め込みの予測ピークに続いて、IFG における言語埋め込みの予測ピークが現れた。この結果は、発話産出と音声理解において、モデル表現と脳活動の対応関係が異なる時間的順序を示すことを示唆する。

以上の結果は、Whisper の内部表現と、人間の言語関連脳活動との間に、自然会話中でも予測可能な機能的整合性が存在することを示す。ただし、この研究は、Whisper と人間の脳が同一の計算原理を実装していること、あるいは脳内の因果的な情報処理経路を Whisper がそのまま再現していることを証明したものではない。

4 提案手法（脳型スパイキング予測符号化システム）

本研究で提案するシステムは、人間の内耳（耳小骨・蝸牛）から脳の一次・二次聴覚野（上側頭回：STG）、そして最終的に音素列を認識する言語エリアへと至る一連の生体情報流を忠実に模倣した 4 つのステージから構成される。本セクションでは、システムのコアとなる「生体模倣聴覚符号化（Stage 1）」、「Predictive e-prop を用いた再帰型スパイキングニューラルネットワーク（RSNN）の自律予測学習（Stage 2）」、「脳活動との機能的・表現的整合性分析（Stage 3）」、および「線形デコーダによる音素認識（Stage 4）」について、特定のベンチマークや具体的な隠れ層規模に依存しない普遍的な数理モデルとして定式化する。

4.1 Stage 1: 音声のスパイキング符号化（入力エンコーディング層）

連続的なアナログ音声データからスパイク列への変換は、SNN の能力を引き出すための最も重要な要素である [33]。入力された連続音声信号 $x(t)$ は、生物学的な聴覚末梢系の処理メカニズムおよび音響心理学を統合した生体模倣聴覚符号化（Biologically plausible Auditory Encoding: BAE）フロントエンド [32] を通じて、極めてスパース（疎）かつ情報保持能力の高い D_{in} 次元の時系列スパイク列へと変換される。このプロセスは、以下の 4 つのステップに一般化される。

4.1.1 コクリア・フィルタバンクによる周波数分解（内耳模倣）

入力連続音声信号 $x(t)$ に対し、人間の基底膜の周波数選択性を模倣するため、中心周波数が等価矩形帯域（Equivalent Rectangular Bandwidth: ERB）スケールまたは定数 Q 変換（Constant Q Transform: CQT）に沿って対数的に配置された K 個のバンドパスフィルタ群を適用する [32]。時間領域での並列畳み込み演算により、各周波数チャンネルのサブバンド信号 $y_k(t)$ ($k = 1, \dots, K$) を次式に従って抽出する。

$$y_k(t) = \int_{-\infty}^{\infty} x(\tau) F_k(t - \tau) d\tau \quad (2)$$

ここで、 $F_k(t)$ は第 k チャンネルにおけるフィルタのインパルス応答関数である。

4.1.2 対数フレームエネルギーの算出

サブバンド信号 $y_k(t)$ のダイナミクスを時間的に捉えるため、フレーム時間窓幅 L_{win} およびシフトストライド L_{step} の時間窓を用いて各フレームに分割し、フレームインデックス j における対数フレームエネルギー $e_k(j)$ を以下のように算出する [32]。

$$e_k(j) = 10 \log_{10} \left(\sum_{q=1}^{N_{\text{sample}}} y_{k,q}^2(j) \right) \quad (3)$$

ここで、 $y_{k,q}(j)$ は第 j フレームにおける第 k チャンネルの第 q 番目のサンプリング値であり、 N_{sample} はフレーム長 L_{win} に対応するサンプル数である。これにより、2 次元の離散時間-周波数スペクトログラム $S \in \mathbb{R}^{K \times N_{\text{frame}}}$ が生成される（ここで $s_{kj} = e_k(j)$ は第 k チャンネル、第 j フレームのエネルギーを表す）。

4.1.3 音響心理学マスキングによる冗長性の除去

人間の知覚限界および時間的・周波数的な注意ダイナミクスを模倣するため、スペクトログラム S に対して同時マスキング（Simultaneous Masking）と時間マスキング（Temporal Masking）を統合した音響心理閾値処理を適用する [32]。周波数軸方向における第 k 周波数バンドの同時マスキング閾値 $T_a(f_k)$ と、時間軸方向の時間マスキング閾値 $y_{\text{temp}}(n)$ は以下のように定式化される。

$$T_a(f_k) = 3.64 \left(\frac{f_k}{1000} \right)^{-0.8} - 6.5e^{-0.6 \left(\frac{f_k}{1000} - 3.3 \right)^2} + 0.001 \left(\frac{f_k}{1000} \right)^4 \quad (4)$$

$$y_{\text{temp}}(n) = C_{\text{decay}} \cdot P_{\text{peak}} \quad (5)$$

ここで、 f_k は第 k チャンネルの中心周波数、 C_{decay} は指数減衰定数、 P_{peak} は直前の極大値（ローカルピーク）におけるスペクトルパワー強度、 n はピーク時からの経過時間フレーム差である。

これら 2 つの閾値の最大値を選択することにより、総合的な動的知覚閾値マップ $M \in \mathbb{R}^{K \times N_{\text{frame}}}$ を構築する。

$$m_{kj} = \max(T_a(f_k), y_{\text{temp}}(j)) \quad (6)$$

この閾値マップ M を用いて、スペクトログラム S を以下の二値評価画像 $\Phi \in \{0, 1\}^{K \times N_{\text{frame}}}$ に変換し、ハダマール積による知覚外（冗長）情報の完全マスキングを実行する [32]。

$$\phi_{kj} = \begin{cases} 1 & \text{if } s_{kj} \geq m_{kj} \\ 0 & \text{if } s_{kj} < m_{kj} \end{cases} \quad (7)$$

$$S_{\text{mask}} = S \circ \Phi \quad (8)$$

4.1.4 ポピュレーション閾値コーディング (Threshold-Crossing)

マスクングを通過したエネルギー変動 S_{mask} から、動的な軌跡情報を効率的にスパイク化するため、各周波数チャンネル k に対して M_{thr} 個のエネルギー閾値 T_θ ($\theta = 1, \dots, M_{\text{thr}}$) を配置した閾値コーディング (Threshold-crossing) を適用する [32]. このアプローチは、冗長なデータの送信を劇的に抑制し、電力効率を飛躍的に高めるイベント駆動型アプローチ (Send-on-Delta) に準拠している [27]. エネルギー信号 s_{kj} がいずれかの閾値 T_θ を交差 (向上交差または下降交差) したイベント発生時刻においてのみスパイクを発火させるため、最終的なエンコーディング層の入力スパイク次元は以下で定義される.

$$D_{\text{in}} = K \times M_{\text{thr}} \quad (9)$$

生成される D_{in} 次元のスパイク列 $P_{\text{mask}}(t) \in \{0, 1\}^{D_{\text{in}}}$ は、音声の動的な「時間-周波数エネルギー軌跡」を忠実に保持しながらも、非活性状態での通信量をほぼ皆無に抑えた、極めて効率的な感覚入力として後段へと供給される.

4.2 Stage 2: Predictive E-prop RSNN の自律予測学習 (隠れ層・聴覚野 STG 模倣)

Stage 1 で生成された D_{in} 次元の入力スパイク列 $P_{\text{mask}}(t)$ は、局所的な再帰結合を持つスパikingニューラルネットワーク (Recurrent Spiking Neural Network: RSNN) に入力される. RSNN 層は、総ニューロン数 N_{rec} 個から構成され、時間ダイナミクスの保持とデコヒーレンスの抑制を両立するため、通常の LIF (Leaky Integrate-and-Fire) ニューロン N_{LIF} 個と、適応型膜閾値を持つ ALIF (Adaptive LIF) ニューロン N_{ALIF} 個を組み合わせた不均一 (Heterogeneous) ネットワークとして定式化される [11].

$$N_{\text{rec}} = N_{\text{LIF}} + N_{\text{ALIF}} \quad (10)$$

4.2.1 ニューロンおよび膜電位ダイナミクス

各ニューロン j ($j = 1, \dots, N_{\text{rec}}$) の膜電位 $v_j(t)$ および動的発火閾値 $A_j(t)$ の時間離散的なダイナミクスは以下の連立方程式で記述される [11, 29].

$$v_j(t+1) = \alpha v_j(t) + \sum_{i=1}^{D_{\text{in}}} w_{ji}^{\text{in}} x_i(t) + \sum_{k=1}^{N_{\text{rec}}} w_{jk}^{\text{rec}} z_k(t) - z_j(t) A_j(t) + I_{\text{bias}} + S_{\text{noise}}(t) \quad (11)$$

ここで、 $\alpha = e^{-dt/\tau_{\text{mem}}}$ は膜電位の指数減衰係数 (τ_{mem} は膜時間定数、 dt は微小シミュレーションステップ幅) であり、 w_{ji}^{in} および w_{jk}^{rec} はそれぞれ入力結合重みと再帰結合重み、 $x_i(t) \in P_{\text{mask}}(t)$ は入力スパイクである. $z_j(t) \in \{0, 1\}$ はニューロン j の発火状態を示し、 $z_j(t) = \Theta(v_j(t) - A_j(t))$ で算出される (Θ はヘヴィサイドの階段関数). I_{bias} は定常バイアス電流、 $S_{\text{noise}}(t)$ は細胞固有の揺らぎを模倣した時間相関を持つオルンシュタイン=ウーレンベックノイズ項である.

ALIF ニューロンにおける動的閾値 $A_j(t)$ は、自身の発火履歴に応じて以下のように閾値が適応的に上昇・減衰する [11].

$$A_j(t) = v_{\text{th}} + \beta a_j(t) \quad (12)$$

$$a_j(t+1) = \rho a_j(t) + z_j(t) \quad (13)$$

ここで、 v_{th} は基礎閾値、 $\rho = e^{-dt/\tau_{\text{alif}}}$ は適応時定数 τ_{alif} に基づく閾値の減衰係数、 β は適応強度パラメータである. LIF ニューロンにおいては $\beta = 0$ となり、常に一定の閾値 $A_j(t) = v_{\text{th}}$ を保持する.

4.2.2 Predictive Coding に基づく自己教師あり前向き予測

本アーキテクチャでは、感覚情報の自律的な獲得および破滅的忘却の回避のため、脳の有力な認知理論である予測符号化理論 (Predictive Coding) [26, 38] を導入する。ネットワーク出力 $y(t) \in \mathbb{R}^{D_{\text{out}}}$ に対し、外部の教示情報 (ラベル) を用いずに「次の微小ステップの入力スパイク変動」を予測する前向きな自己教師あり予測学習 (Predictive Self-Supervised Learning) を課す [29]。第 k 次元の予測出力 $y_k(t)$ は、RSNN 層の平滑化スパイク活動 $\bar{z}(t)$ から線形に射影される。

$$y_k(t) = \sum_{j=1}^{N_{\text{rec}}} w_{kj}^{\text{out}} \bar{z}_j(t) \quad (14)$$

ここで $\bar{z}_j(t)$ は発火活動 $z_j(t)$ を二重指数フィルタ (ライズ/ディケイ時間定数 τ_r, τ_d) に通した長期的活動トレースである。このとき最小化すべき自律的予測誤差エネルギー E_{pred} は次式で定義される [29]。

$$E_{\text{pred}} = \frac{1}{2} \sum_t \sum_{k=1}^{D_{\text{out}}} (y_k(t) - x_k(t))^2 \quad (15)$$

ここで $x_k(t)$ は予測の正解 (Target) となる時系列感覚信号の第 k 次元表現である。

4.2.3 Predictive E-prop による局所重み更新

大域的な時間逆伝播 (BPTT) を排除し、生体脳の生物学的妥当性を満たすオンラインローカル学習を実現するため、再帰シナプス重み w_{jk}^{rec} の更新には e-prop 則 [3] を適用する。Predictive e-prop モデルでは、神経修飾因子に相当する「第 3 の因子 (学習シグナル)」が大域的な報酬やラベル誤差ではなく、完全にローカルな予測誤差から直接導出される [29]。学習勾配 $\Delta w_{jk}^{\text{rec}}$ は、トップダウンのエラー情報を伝達する学習シグナル $L_j(t)$ と、各シナプスが自律的に保持する適格性トレース (Eligibility Trace) $e_{jk}(t)$ の局所的な積のオンライン累積として算出される [3]。

$$\Delta w_{jk}^{\text{rec}} = \eta \sum_t L_j(t) \cdot e_{jk}(t) \quad (16)$$

ここで η は学習率を表す。学習シグナル $L_j(t)$ は、予測誤差 $(y(t) - x(t))$ にランダムフィードバック行列 B によるブロードキャスト・アライメント (Broadcast Alignment) を適用することで、各ニューロンに局所的に伝達される [29]。

$$L_j(t) \approx \frac{\partial E_{\text{pred}}}{\partial z_j(t)} = \sum_{d=1}^{D_{\text{out}}} B_{jd} (y_d(t) - x_d(t)) \frac{1}{\tau_r \tau_d} \quad (17)$$

一方、適格性トレース $e_{jk}(t)$ は、前シナプス発火活動 $z_k(t)$ と後シナプスニューロン j の膜電位および適応ダイナミクスの微分 (サロゲート勾配近似 $\psi_j(t)$ を含む) の局所的な相関関係に基づき、時間方向に前方計算によってリアルタイムに蓄積される [3, 29]。

$$e_{jk}(t) = \psi_j(t) (\bar{z}_k(t-1) - \beta \epsilon_{jk, \text{adapt}}(t)) \quad (18)$$

ここで $\psi_j(t)$ は、微分不可能であるステップ関数の勾配を補完するためのテント型サロゲート勾配近似関数であり [28]、 $\epsilon_{jk, \text{adapt}}(t)$ は ALIF の膜閾値適応特性に起因する履歴保存変数である。この数理化式化により、RSNN は外部からの大域的教師信号を一切受けることなく、各シナプスの局所的ダイナミクスのみに基づいて、環境 (音声) の動的パターンを時間依存的に予測する内部生成モデルを自律的に獲得する [29]。

4.3 Stage 3: SNN 活動解析および脳活動 (ECoG) データとの機能的・表現的整合性分析

Stage 2 において Predictive e-prop により自律学習を行った RSNN の内部表現の生物学的妥当性を評価するため、本ステージでは特定の隠れ層規模に依存しない普遍的な多角的・一般化解析フレームワークを適用する。平滑化された N_{rec} 次元の状態ダイナミクスベクトル $\bar{\mathbf{z}}(t) \in \mathbb{R}^{N_{\text{rec}}}$ に対し、以下の 4 つの解析手法を定義する。

4.3.1 多重スパイク列の並列時間評価 (ラスタプロット解析)

RSNN を構成する全 N_{rec} 個のニューロンの個別かつ協調的な時間的発火パターン $z_i(t)$ ($i = 1, \dots, N_{\text{rec}}$) を時間軸に対してラスタプロットとして並列展開する。母音・子音や各音素、および動的な音響インパルスに対するニューロン集団の同期発火動態を検証する [11]。

4.3.2 潜在空間における幾何学的軌跡解析 (状態空間軌跡)

時系列推移する RSNN の隠れ状態ベクトル $\bar{\mathbf{z}}(t) \in \mathbb{R}^{N_{\text{rec}}}$ について、高次元潜在空間における幾何学的ダイナミクスを解析する。次元削減写像 $g_{\text{proj}}: \mathbb{R}^{N_{\text{rec}}} \rightarrow \mathbb{R}^d$ ($d \ll N_{\text{rec}}$) (PCA や t-SNE 等) を用いて低次元空間へ状態を投影し、投影された状態軌跡が、入力音声の音響・音素カテゴリの境界を反映し、状態空間上でどのように幾何学的なクラスターを形成するかを解析する [29]。

4.3.3 頭蓋内脳電図 (ECoG) データとの多角的アライメント評価

本モデルが「生体脳 (一次・二次聴覚野 STG 等) と同様の表現トポロジー」を自律的に獲得しているかをダイレクトに評価するため、皮質応答予測と幾何学的直接比較を統合した 4 つの機能的整合性アライメント定式化を導入する。

■A) 線形エンコーディングモデルによる皮質応答予測 (Ridge Regression) 同一の音響刺激を入力した際の RSNN 隠れ層ダイナミクス $\bar{\mathbf{z}}(t) \in \mathbb{R}^{N_{\text{rec}}}$ から、被験者の聴覚皮質に留置された電極における High-gamma 帯域 (75–200 Hz) の時間変動脳活動波形 $r_c(t)$ ($c = 1, \dots, C$; C は総電極数) を予測する線形リッジ回帰モデルを構築する [12]。

$$\hat{r}_c(t) = \mathbf{w}_c^\top \bar{\mathbf{z}}(t) + b_c \quad (19)$$

ここで、 $\mathbf{w}_c \in \mathbb{R}^{N_{\text{rec}}}$ は L2 正則化を伴う最小二乗法で推定される重みベクトルであり、正則化パラメータ λ_{ridge} を用いて以下の目的関数を最小化する。

$$\mathcal{L}_{\text{ridge}}(\mathbf{w}_c) = \sum_t (r_c(t) - \hat{r}_c(t))^2 + \lambda_{\text{ridge}} \|\mathbf{w}_c\|_2^2 \quad (20)$$

未知のテスト音声に対するモデル予測値 $\hat{r}_c(t)$ と、実際の脳活動 $r_c(t)$ のピアソン相関係数 r_{Pearson} を算出し、モデル表現の脳活動説明率を定量化する [12]。

■B) 表現類似性解析 (Representational Similarity Analysis: RSA) 回帰マッピングを挟まず、モデルと生体脳の「表現トポロジー (刺激間の相対的な幾何学構造)」をダイレクトに比較する [19]。同一の刺激セット (P 個の異なる音響刺激) に対する SNN の時間平均平滑化活動 $\bar{\mathbf{z}}^{(p)}$ ($p = 1, \dots, P$) から、ペア間のコサイン距離を算出し、刺激間の類似度関係を記録した $P \times P$ 次元のモデル表現選別行列 $\mathbf{RDM}_{\text{SNN}} \in \mathbb{R}^{P \times P}$ を構築

する。その各要素 $d_{p,q}^{\text{SNN}}$ は次式で定義される。

$$d_{p,q}^{\text{SNN}} = 1 - \frac{\bar{\mathbf{z}}^{(p)} \cdot \bar{\mathbf{z}}^{(q)}}{\|\bar{\mathbf{z}}^{(p)}\|_2 \|\bar{\mathbf{z}}^{(q)}\|_2} \quad (21)$$

同様に、同一刺激セットに対する脳活動応答 $\mathbf{r}^{(p)} \in \mathbb{R}^C$ から脳表現選別行列 $\mathbf{RDM}_{\text{ECoG}} \in \mathbb{R}^{P \times P}$ を構築し、この2つの行列の非対角成分をベクトル化 (vech) してスピアマンの相関係数を算出することで、アライメントスコアを定義する [19]。

$$\text{RSA-alignment} = \text{corr}(\text{vech}(\mathbf{RDM}_{\text{SNN}}), \text{vech}(\mathbf{RDM}_{\text{ECoG}})) \quad (22)$$

■C) Centered Kernel Alignment (CKA) による高次元表現空間ダイレクトアライメント SNN の時系列活動行列 $\mathbf{X} \in \mathbb{R}^{T \times N_{\text{rec}}}$ と、ECoG の活動行列 $\mathbf{Y} \in \mathbb{R}^{T \times C}$ について、サンプルの時間アライメントを合わせた状態で表現空間自体の類似性をダイレクトに定量化する [18]。線形 CKA は、内積カーネル $\mathbf{K} = \mathbf{X}\mathbf{X}^\top$ および $\mathbf{L} = \mathbf{Y}\mathbf{Y}^\top$ を用いて以下のように定式化される。

$$\text{CKA}(\mathbf{X}, \mathbf{Y}) = \frac{\text{HSIC}(\mathbf{K}, \mathbf{L})}{\sqrt{\text{HSIC}(\mathbf{K}, \mathbf{K})\text{HSIC}(\mathbf{L}, \mathbf{L})}} \quad (23)$$

ここで、HSIC はヒルベルト・シュミット独立基準の不偏推定量であり、時間軸中心化行列 $\mathbf{H} = \mathbf{I}_T - \frac{1}{T}\mathbf{1}\mathbf{1}^\top$ を用いて $\text{HSIC}(\mathbf{K}, \mathbf{L}) = \frac{1}{(T-1)^2} \text{tr}(\mathbf{H}\mathbf{K}\mathbf{H}\mathbf{L})$ として計算される。

■D) スパイク-場電位同期 (Spike-Field Coherence: SFC) SNN の固有特性である「離散パルス発火」を活用し、局所電位 (LFP) に相当する ECoG のオシレーションとの時間同期ダイナミクスをマイクロ秒精度で評価する。特定のニューロン i の全発火時刻集合を $\mathcal{T}_i = \{t_{\text{spike}}^{(1)}, t_{\text{spike}}^{(2)}, \dots\}$ とするとき、各発火タイミングの前後における脳活動電位 $r_c(t)$ の加算平均 (STA: Spike-Triggered Average) を算出する。また、周波数領域における同期度を定量化するため、スパイク列 ($z_i(t) = \sum_{t_s \in \mathcal{T}_i} \delta(t - t_s)$) と脳電位 $r_c(t)$ のコヒーレンス (SFC) を、クロススペクトル $S_{zr}(f)$ と自己スペクトル $S_{zz}(f)$, $S_{rr}(f)$ を用いて算出する [10]。

$$\text{SFC}_{i,c}(f) = \frac{|S_{zr}(f)|^2}{S_{zz}(f)S_{rr}(f)} \quad (24)$$

これにより、人工スパイクニューロンの個々の自律的な発火が、生体脳のニューロン集団の同期オシレーションとミリ秒レベルで直接コヒーレントに同調しているかを実証する [10]。

4.4 Stage 4: 線形デコーダによる音素分類 (出力層・言語野)

自律学習した RSNN の内部表現の有用性を評価するため、学習済みの再帰結合重み $\mathbf{W}^{\text{rec}}$ および入力重み $\mathbf{W}^{\text{in}}$ を完全に固定した状態で、その最上部に極めて表現力の限定されたシンプルな1層の線形全結合デコーダ (Linear Readout Decoder) を配置し、音素認識タスクを課す [29]。

RSNN の平滑化活動ベクトル $\bar{\mathbf{z}}(t) \in \mathbb{R}^{N_{\text{rec}}}$ から、認識対象とする P_{class} 次元の音素クラス事後確率 $\mathbf{p}(t) \in \mathbb{R}^{P_{\text{class}}}$ への写像は、デコーダ重み $\mathbf{W}^{\text{read}} \in \mathbb{R}^{P_{\text{class}} \times N_{\text{rec}}}$, バイアス $\mathbf{b}^{\text{read}} \in \mathbb{R}^{P_{\text{class}}}$, およびソフトマックス関数を用いて以下のように定義される。

$$\mathbf{a}(t) = \mathbf{W}^{\text{read}}\bar{\mathbf{z}}(t) + \mathbf{b}^{\text{read}} \quad (25)$$

$$p_k(t) = \frac{e^{a_k(t)}}{\sum_{j=1}^{P_{\text{class}}} e^{a_j(t)}}, \quad k = 1, \dots, P_{\text{class}} \quad (26)$$

この Readout 層のみのパラメータ ($\mathbf{W}^{\text{read}}$) に対し, Connectionist Temporal Classification (CTC) 損失またはフレーム単位のカロスエントロピー損失 $\mathcal{L}_{\text{class}}$ を用いて教師あり高速最適化を実行する. この極めて低容量な線形デコーダのみの調整によって高精度な音素分類が達成されることは, 前段の Predictive e-prop RSNN が感覚空間からの自律学習のみにより, 高次元状態空間上であらゆる音素情報を「線形分離可能な幾何トポロジー」として自己組織的に整理できていることを数学的に証明する [29].

5 現在の状況と今後の実験計画

5.1 現在までの進捗状況

現在, 提案システムにおける開発のフェーズは以下の状況にある.

1. Stage 1: 音声のスパイク化 (BAE フロントエンド) の MATLAB 実装完了 (進捗 100%) :

MATLAB コード (`encode_single_wav.m`) による BAE ツール群の実装と, 入力連続波形から 620 次元のスパイク列を生成するエンコーダプログラムが完成している. テスト音声 (TIMIT, Podcast) を適用し, 同時マスキング $Ta(f)$ および時間マスキングの計算, および閾値判定により, 音声の情報ダイナミクスを前向きに保持したまま, 発火率を約 50% 削減した極めてスパースなスパイク列が正常に出力されることを波形・ラスタプロットにて確認・検証済みである.

2. Stage 2: Predictive E-prop RSNN の自律学習の再現検証 (進捗 40%) :

Network.py 上の PredictiveEPropRSNN を定義し, E-prop 自律学習アルゴリズム (Bellec et al., 2020; Noe et al., 2026) の再現・検証コードを構築中である. 現在は, 公開されている既存文献のベンチマーク実験 (合成信号や簡易時系列タスク) を用いて, 大域的 BPTT を用いない適格性トレースによるオンライン重み更新が意図通り安定して収束するかどうかの, 再現検証を行っている段階である.

5.2 今後の実験計画

今後の中間・最終報告に向け, 以下のステップで実証評価を進める.

● ステップ 1 : Stage 1 と Stage 2 の接続 (2026 年 9 月中旬まで) :

構築した BAE エンコーダで変換した TIMIT データおよび Podcast 音声のスパイク列を, Predictive E-prop RSNN の入力としてパイプライン接続する. 高次元 (620 次元) スパイク列の時間変動予測タスクにおいて, 自律学習 (RSNN 再帰重みの更新) を動作させ, 膜電位や適格性トレースの安定性をチューニングする.

● ステップ 2 : 線形デコーダ接続による音声認識性能の測定 (2026 年 10 月下旬まで) :

TIMIT データセットを用いて線形 Readout デコーダを学習させ, フレームごとの音素分類精度, および CTC を用いた音素エラー率 (PER : Phone Error Rate) を算出する. 同時に, 計算中の累積スパイク発火数をカウントすることで, 従来の ANN と比較した際のモデルの「極めて高いエネルギー効率 (スパース通信効果)」を定量化して検証する.

● ステップ 3 : 内部ダイナミクス可視化とクラスタリング分析 (2026 年 9 月下旬まで) :

学習済みモデルの隠れ層発火からラスタプロットを出力する. また, 各フレームでの 300 次元状態を PCA/t-SNE によって低次元展開し, 状態軌跡が母音 ($/a/$, $/i/$, $/u/$ 等) や子音といった音響音素カテゴリ

ごとに空間上でどのように幾何学的なクラスタを形成するか、その自己組織化能力を視覚的に評価する。

- **ステップ 4: ECoG データとの脳活動機能的整合性・直接アライメント評価 (2026 年 10 月中旬まで)** : OpenNeuro の「Podcast」 ECoG dataset」を活用し、図??に示す線形エンコーディングモデル (Ridge 回帰) に加え、パラメータフィッティングを必要としない表現類似性解析 (RSA), Centered Kernel Alignment (CKA), および Spike-Field Coherence (SFC) や Spike-Triggered Average (STA) を用いたスパイク-LFP 直接同期解析を実装する。本モデルの隠れ層発火およびダイナミクスと、実被験者の一次聴覚野 (STG) や言語エリア (IFG など) における High-gamma 神経活動の間のアライメントスコアを、トポロジー幾何・時系列同期・予測精度の多角的な視点から算出し、生物学的な妥当性を学術的に徹底検証する。

6 まとめ

本研究は、現代 AI の課題であるエネルギー非効率性を克服するために、脳の低電力動作原理 (SNN + 予測符号化) を音声認知システムへと拡張する先進的な試みである。

これまでに、耳・蝸牛の精緻な符号化と心理音響マスキングを模倣した「Stage 1 (BAE)」の開発を完了し、現在、聴覚野に相当する自律的予測学習システム「Stage 2 (Predictive E-prop RSNN)」の再現および数理的な調整を進めている。

今後は、Stage 1 と 2 の統合を進めるとともに、OpenNeuro 公開の「Podcast」 ECoG」脳信号データセットとの機能的整合性分析 (脳活動アライメント評価) を行い、本提案モデルが脳の音声・言語処理プロセスをどの程度忠実に自己組織化できているかを検証する。この結果は、学術的な計算論的神経科学への貢献だけでなく、次世代の省電力ニューロモルフィックエッジハードウェア向けの音声認識・聴覚センサーフロントエンド技術としての応用展開が期待される。

参考文献

- [1] E. D. Adrian and Y. Zotterman. The impulses produced by sensory nerve endings: Part 3: Impulses set up by touch and pressure. *The Journal of Physiology*, 61(4):465, 1926.
- [2] S. Baek and J. Lee. Snn and sound: a comprehensive review of spiking neural networks in sound. *Biomedical Engineering Letters*, 14(5):981–991, 2024.
- [3] G. Bellec, F. Scherr, A. Subramoney, E. Hajek, D. Salaj, R. Legenstein, and W. Maass. A solution to the learning dilemma for recurrent networks of spiking neurons. *Nature communications*, 11(1):3625, 2020.
- [4] G. Q. Bi and M. M. Poo. Synaptic modifications in cultured hippocampal neurons: dependence on spike timing, synaptic strength, and postsynaptic cell type. *Journal of Neuroscience*, 18(24):10464–10472, 1998.
- [5] Y. Cao, Y. Chen, and D. Khosla. Spiking deep convolutional neural networks for energy-efficient object recognition. *International Journal of Computer Vision*, 113(1):54–66, 2015.
- [6] X. Chen, Q. Yang, J. Wu, H. Li, and K. C. Tan. A hybrid neural coding approach for pattern recognition with spiking neural networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2023.

- [7] P. U. Diehl, D. Neil, J. Binas, M. Cook, S. C. Liu, and M. Pfeiffer. Fast-classifying, high-accuracy spiking deep networks through weight and threshold balancing. In *International Joint Conference on Neural Networks (IJCNN)*, pp. 1–8, 2015.
- [8] M. Dong, X. Huang, and B. Xu. Unsupervised speech recognition through spike-timing-dependent plasticity in a convolutional spiking neural network. *PLoS One*, 13(11):e0204596, 2018.
- [9] C. Eliasmith and C. H. Anderson. *Neural engineering: computation, representation, and dynamics in neurobiological systems*. MIT Press, 2003.
- [10] P. Fries. A mechanism for cognitive dynamics: neuronal communication through neuronal coherence. *Trends in cognitive sciences*, 9(10):474–480, 2005.
- [11] W. Gerstner, W. M. Kistler, R. Naud, and L. Paninski. *Neuronal dynamics: From single neurons to networks and models of cognition*. Cambridge University Press, 2014.
- [12] A. Goldstein, H. Wang, L. Niekerken, M. Schain, Z. Zada, B. Aubrey, T. Sheffer, S. A. Nastase, H. Gazula, A. Singh, et al. A unified acoustic-to-speech-to-language embedding space captures the neural basis of natural language processing in everyday conversations. *Nature human behaviour*, 9(5):1041–1055, 2025.
- [13] W. Guo, M. E. Fouda, A. M. Eltawil, and K. N. Salama. Neural coding in spiking neural networks: a comparative study for robust neuromorphic systems. *Frontiers in Neuroscience*, 15:638474, 2021.
- [14] B. Han, G. Srinivasan, and K. Roy. Rmp-snn: Residual membrane potential neuron for enabling deeper high-accuracy and low-latency spiking neural network. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 13555–13564, 2020.
- [15] S. Herculano-Houzel. Scaling of brain metabolism with a fixed energy budget per neuron: implications for neuronal activity, plasticity and evolution. *PloS one*, 6(3):e17514, 2011.
- [16] L. A. Jeffress. A place theory of sound localization. *Journal of Comparative and Physiological Psychology*, 41(1):35, 1948.
- [17] V. Karlsson, N. Fianda, and J.-K. Kamarainen. Difference predictive coding for training spiking neural networks. In *International Conference on Learning Representations*, Vol. 2026, pp. 104022–104041, 2026.
- [18] S. Kornblith, M. Norouzi, H. Lee, and G. Hinton. Similarity of neural network representations revisited. In *International conference on machine learning*, pp. 3519–3529. PMIR, 2019.
- [19] N. Kriegeskorte, M. Mur, and P. A. Bandettini. Representational similarity analysis-connecting the branches of systems neuroscience. *Frontiers in systems neuroscience*, 2:249, 2008.
- [20] B. M. Lake, T. D. Ullman, J. B. Tenenbaum, and S. J. Gershman. Building machines that learn and think like people. *arXiv preprint arXiv:1604.00289*, 2016.
- [21] J. H. Lee, T. Delbruck, and M. Pfeiffer. Training deep spiking neural networks using backpropagation. *Frontiers in Neuroscience*, 10:228000, 2016.
- [22] Q. Liu, D. Xing, L. Feng, H. Tang, and G. Pan. Event-based multimodal spiking neural network with attention mechanism. In *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 8922–8926, 2022.
- [23] F. Martinelli, G. Dellaferrera, P. Mainar, and M. Cernak. Spiking neural networks trained with backpropagation for low power neuromorphic implementation of voice activity detection. In *IEEE*

- International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 8544–8548, 2020.
- [24] T. Masquelier and S. J. Thorpe. Unsupervised learning of visual features through spike timing dependent plasticity. *PLoS Computational Biology*, 3(2):e31, 2007.
 - [25] M. McCloskey and N. J. Cohen. Catastrophic interference in connectionist networks: The sequential learning problem. In *Psychology of learning and motivation*, Vol. 24, pp. 109–165. Elsevier, 1989.
 - [26] B. Millidge, A. Seth, and C. L. Buckley. Predictive coding: a theoretical and experimental review. *arXiv preprint arXiv:2107.12979*, 2021.
 - [27] M. Miskowicz. Send-on-delta concept: an event-based data reporting strategy. *Sensors*, 6(1):49–63, 2006.
 - [28] E. O. Neftci, H. Mostafa, and F. Zenke. Surrogate gradient learning in spiking neural networks: bringing the power of gradient-based optimization to spiking neural networks. *IEEE Signal Processing Magazine*, 36(6):51–63, 2019.
 - [29] D. Noè, H. Yamamoto, Y. Katori, and S. Sato. Predictive e-prop: A biologically inspired approach to train predictive coding-based recurrent spiking neural networks. *bioRxiv*, pp. 2026–02, 2026.
 - [30] G. Oliviers, M. Tang, and R. Bogacz. Bidirectional predictive coding. In *International Conference on Learning Representations*, Vol. 2026, pp. 59585–59619, 2026.
 - [31] A. M. M. Oswald, B. Doiron, and L. Maler. Interval coding. i. burst interspike intervals as indicators of stimulus intensity. *Journal of Neurophysiology*, 97(4):2731–2743, 2007.
 - [32] Z. Pan, Y. Chua, J. Wu, M. Zhang, H. Li, and E. Ambikairajah. An efficient and perceptually motivated auditory neural encoding and decoding algorithm for spiking neural networks. *Frontiers in neuroscience*, 13:1420, 2020.
 - [33] S. S. Park and Y.-S. Choi. Spiking neural networks for physiological and speech signals: a review. *Biomedical Engineering Letters*, 14(5):943–954, 2024.
 - [34] D. Patterson, J. Gonzalez, Q. Le, C. Liang, L.-M. Munguia, D. Rothchild, D. So, M. Texier, and J. Dean. Carbon emissions and large neural network training. *arXiv preprint arXiv:2104.10350*, 2021.
 - [35] F. Ponulak and A. Kasinski. Introduction to spiking neural networks: Information processing, learning and applications. *Acta Neurobiologiae Experimentalis*, 71(4):409–433, 2011.
 - [36] N. Rathi and K. Roy. Stp based unsupervised multimodal learning with cross-modal processing in spiking neural networks. *IEEE Transactions on Emerging Topics in Computational Intelligence*, 5(1):143–153, 2018.
 - [37] D. E. Rumelhart, G. E. Hinton, and R. J. Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986.
 - [38] M. V. Srinivasan, S. B. Laughlin, and A. Dubs. Predictive coding: a fresh view of inhibition in the retina. *Proceedings of the Royal Society of London. Series B, Biological Sciences*, pp. 427–459, 1982.
 - [39] G. M. Van de Ven, H. T. Siegelmann, and A. S. Tolias. Brain-inspired replay for continual learning with artificial neural networks. *Nature communications*, 11(1):4069, 2020.
 - [40] P. J. Werbos. Backpropagation through time: what it does and how to do it. *Proceedings of the IEEE*, 78(10):1550–1560, 1990.

- [41] 砂川恵太郎. 双方向予測符号化のスパイキングニューラルネットワークへの実装による計算コストの削減. <https://tus.box.com/s/x7gc8ujqimsum79g2l5q28xwzvmstcvn>, 2026.