

1 要旨

近年、大規模言語モデル（LLM）に代表される深層生成 AI は目覚ましい性能を示しているものの、その運用に必要な膨大な計算資源とデータ量、および「破滅的忘却」といった脳科学的な乖離が課題となっている。本研究では、脳の低電力インメモリ計算およびイベント駆動型スパース処理を模倣するスパイキングニューラルネットワーク（SNN）と、自己組織化的なオンライン学習を可能にする「予測符号化理論（Predictive Coding）」を統合した、新しい音声・聴覚認知システムの構築を目指す。

筆者の先行研究では、手書き数字画像タスクにおいて双方向予測符号化モデル（Diff-bPC）の実装と評価を行ってきた。本研究は、これを時間軸方向の動的なパターン処理が必要とされる「音声認識」タスクへと拡張するものである。

具体的には、人間の耳から聴覚野、言語野にいたる情報処理流を模倣した 4 つのステージ（Stage 1~4）からなる脳型音声認識システムを構築する。現在までに、生体模倣聴覚符号化（BAE）を用いた音声のスパイク化（Stage 1）の実装を完了し、時間予測に基づく自律学習則である Predictive E-prop（Stage 2）の再現・調整を行っている。本稿では、各パーツの詳細な構成、現在までの進捗状況、および OpenNeuro 公開の "Podcast" ECoG (electrocorticography, 皮質脳波) データセットを用いた脳機能機能的アライメント（相関解析）の評価計画について報告する。

2 背景と目的

現在、主流となっている人工知能（AI）やそれに含まれる大規模言語モデル（LLM）は、特定のタスクや推論において人間を凌駕する性能に到達している。しかし、その成功は数ギガワット級の巨大な計算インフラと膨大な炭素排出を伴うもの [34] であり、極めて高い計算資源コストとエネルギー非効率性に直面している。また、これらのモデルは数兆トークンに及ぶ莫大なデータから表現を学習する一方、生体脳のように限られたサンプルから効率的に汎化（Few-shot 学習）する柔軟性を欠いている [20]。さらに、新しい環境や追加のタスクに適応させようとすると、既存の学習済み表現が破壊的に上書きされる「破滅的忘却」[25, 39] が深刻な問題となっている。

これに対し、人間の脳は約 20W という極めて微小な電力で動作し、リアルタイムに外界の複雑なマルチモーダル情報を認識・処理する [15]。この圧倒的なエネルギー効率の源泉は、フォン・ノイマン・ボトルネックを克服したシナプス結合による「インメモリ計算」と、必要な情報が到来したときにのみスパイクを介して非同期的に通信・計算を行う「イベント駆動型スパース処理」にある。

この生体脳の卓越した特性を模倣するために、第三世代のニューラルネットワークであるスパイキングニューラルネットワーク（SNN）が近年活発に研究されている。SNN は、時間情報を伴う $\{0, 1\}$ （あるいは極性を持つ $\{-1, 0, 1\}$ ）のパルス状信号である「スパイク」で通信を行う。これにより計算負荷を飛躍的に削減できるが、微分不可能という数学的障壁のため、大域的な「誤差逆伝播法（Backpropagation）」の直接的な適用が極めて困難である。ただし、誤差逆伝播法はネットワーク全体で詳細な大域的誤差情報を即座に共有する必要があり、生体脳のシナプスが局所的な（ローカルな）情報のみで自己組織的に学習している事実（生物学的妥当性）とはミスマッチしているため、SNN にそれを導入するかは議論の余地がある。

この課題を解決する有力なアプローチが、脳の認知理論である「予測符号化理論（Predictive Coding）」[26, 38] である。予測符号化は、上位層からのトップダウンの「予測」と、感覚入力との「予測誤差」を直近の層間で

局所的に最小化することで、大域的な誤差共有なしに表現学習を実現する。

本研究は、筆者の先行研究である画像ベースの双方向予測符号化 SNN 「Difference Bi-Predictive Coding (Diff-bPC)」 [41] の知見を基盤とする。静的な空間パターン（画像）の処理から、時間的な動的パターンを扱う「音声・聴覚認知」への拡張は、脳型 AI のエネルギー効率を実用に耐えうるシステムへと飛躍させるための重要なマイルストーンである。本研究では、人間の聴覚音声処理階層（蝸牛、聴神経、聴覚野、言語野）を統合的に模倣し、高効率かつ高精度な脳型音声認識システムを構築することを目的とする。

3 関連研究

3.1 先行研究：Difference Bi-Predictive Coding (Diff-bPC)

筆者は、識別（ボトムアップ）と生成（トップダウン）を同時に扱う「Difference Bi-Predictive Coding (Diff-bPC)」 [41] を提案し、SNN への実装を行ってきた。このモデルは、3 値スパイク（ $\{-1, 0, 1\}$ ）をベースとした「Difference Predictive Coding」 (DiffPC) [17] に、識別と生成を同一のエネルギー関数に組み込むことで、両方の予測誤差の最小化を両立した「Bidirectional Predictive Coding」 (bPC) [30] の双方向性を取り入れたものである。学習の基盤となるエネルギー関数には、トップダウン生成的予測誤差 ϵ_l^{gen} とボトムアップ識別的予測誤差 ϵ_l^{disc} を同時に最小化する bPC で定義されたものを採用した。

$$E(x, W, V) = \sum_{l=1}^{L-1} \frac{\alpha_{\text{gen}}}{2} \|x_l - W_{l+1}f(x_{l+1})\|_2^2 + \sum_{l=2}^L \frac{\alpha_{\text{disc}}}{2} \|x_l - V_{l-1}f(x_{l-1})\|_2^2 \quad (1)$$

ここで、 x_l は第 l 層 of ニューロン活動、 W は生成（トップダウン）重み、 V は識別（ボトムアップ）重みであり、 f は活性化関数である。この局所的な予測誤差更新式と動的閾値 T_θ の巡回スケジューリングにより、MNIST 手書き数字データセットにおいて 93.84% の分類精度を達成しつつ、従来の非 SNN 双方向モデル (bPC) と比較して層間通信量を大幅に削減することに成功した。しかし、スパイク化に伴う情報の欠落から、識別精度および画像生成画像品質において非 SNN モデルと比較して課題が残されており、このアプローチをさらにロバストで時間情報処理に適したシステムへと拡張する必要性が生じていた。

3.2 SNN 音声認識の動向

本セクションでは、レビュー論文 [2, 33] を基に音声処理向け SNN における基盤技術である「スパイク・エンコーディング」と、ネットワークを最適化するための「学習則」の最新の研究動向について整理し、本研究における提案手法の位置付けを明確にする。

音声波形のような連続的なアナログ時系列データを SNN へ適用する上で、まず必要となるのが入力信号を離散的なスパイク列に変換するスパイク・エンコーディング技術である [33]。この符号化手法は、主にレートコーディング（頻度符号化）とテンポラルコーディング（時間符号化）の 2 つのアプローチに大別される。レートコーディングは、入力信号の強度を単位時間あたりのスパイク発火頻度にマッピングする直感的な手法であり [13]、一定の時間窓内で生成されたスパイク総数に注目するカウントレート [1] や、スパイク間の時間的近接度に着目した密度レート [11]、さらには複数のニューロンの活動パターンとして多次元情報を捉えるポピュレーションレート [9] などが挙げられる。これに対し、スパイクが発生する精密な時間（タイミングや間隔）そのものに情報を保持させるテンポラルコーディングは、時間分解能に優れたより生物学的妥当性の高い手法である [35]。代表的なものとして、刺激強度を最初のスパイクが発生するまでの遅延時間に反比例させる

Time-to-First-Spike (TTFS) や、連続するスパイク間の時間間隔を利用する Interspike Interval (ISI) [31] が存在する。また、入力信号の振幅変化が一定の閾値を超えた場合にのみ発火させる Send-on-Delta (SOD) は、冗長なデータの送信を劇的に抑制し、電力効率を飛躍的に高めるイベント駆動型アプローチとして注目を集めている [27]。近年では、これらのアプローチを組み合わせたハイブリッド符号化モデル [6] や、人間の聴覚末梢系のダイナミクスを反映した聴覚フィルタバンクに基づく符号化手法も数多く提案されている。

SNN の機能性を高め、複雑なタスクへの適応を可能にする第 2 のコア技術が、スパイクの不連続かつ非微分的な性質を克服するための学習則である。現在の学習則は主に、生物学的に妥当な学習、勾配ベースの直接学習、および ANN からの変換技術 (ANN-to-SNN 変換) の 3 つのアプローチに沿って発展を遂げている。生物学的な学習則の代表例であるスパイクタイミング依存可塑性 (Spike-Timing-Dependent Plasticity: STDP) は、前後のニューロンが発火するミリ秒単位の時間差に基づきシナプス荷重を自己組織的に更新する規則である [4]。これは教師なしでの局所的な特徴抽出に極めて適しており、音声認識システムの前処理層や自動特徴抽出器として応用されている [8, 24]。一方、近年の深層 SNN の認識精度を劇的に向上させたのが勾配ベースの直接学習手法である。微分不可能なスパイク発生関数に対して逆伝播時に滑らかな近似関数を代入するサロゲート勾配 (Surrogate Gradient) 法の登場により [28]、時系列の誤差逆伝播法 (Backpropagation Through Time: BPTT) [37, 40] の適用が可能となった。これにより、音声コマンド認識、音声区間検出 (VAD) [23] などのタスクにおいて、高い認識精度を持つ多層 SNN の直接学習 [21] が実現されている。また、別のアプローチとして、既存の高精度な学習済み ANN のシナプス重みとバイアス値を、閾値やリセット機構を調整しながら SNN へと写像する ANN-to-SNN 変換技術 [5, 7] も広く実用されており、変換時の情報損失を最小限に抑えるソフトリセット (膜電位の調整) 機構 [14] などの技術も研究されている。

このように、SNN を用いた音声処理研究は、エンコーディングから学習則に至るまで多角的なアプローチによって進化を遂げており、近年では音源定位の高度化 [16] や、音響情報と視覚情報をシナプスレベルで統合するマルチモーダル SNN への展開 [22, 36] といった応用範囲の広がりを見せている。しかし、実用的な音声認識タスクにおいて高精度かつ真に低遅延なシステムを実装するためには、依然としていくつかの共通課題が残されている。具体的には、勾配ベースの学習 (BPTT) における莫大な時系列計算負荷、音声の音響ダイナミクスを最も損なわずにスパイク情報へと集約できる最適なエンコーディングアルゴリズムの未確立、およびニューロモフィックチップへ展開する際のエネルギー・遅延効率のさらなる最適化などが挙げられる。本研究で提案する手法は、これら既存の動向と課題を見据えた上で、特定の課題に対するブレイクスルーとなるアプローチを提供するものである。

3.3 生体模倣聴覚符号化 (BAE)

音声波形から高効率なスパイク列への変換は、SNN の能力を引き出すための最も重要な要素の一つである。Pan ら [32] が提案した「Biologically plausible Auditory Encoding (BAE)」は、従来の単純なレートコーディング (Rate Coding) や時間・レイテンシコーディングの限界を克服する符号化法である。BAE は、人間の内耳 (蝸牛) のフィルタリング、インナーヘアセルの変換特性に加え、音響心理学的な「マスキング効果 (同時マスキングおよび時間マスキング)」を統合的にモデル化している。これにより、人間が知覚不可能な (聴こえない) 微小な音声帯域や、大振幅音の直後に生じる時間的減衰領域を「無効なデータ (冗長性)」として完全に除去し、スパイクを極めてスパース (疎) に抑えつつも、高い知覚品質と高い分類精度を維持できることが証明されている。

3.4 Whisper モデルと脳活動の整合性

近年の計算論的神経科学では、深層マルチモーダル音声言語モデルと生体脳における言語処理表現の間に、予測可能な機能的整合性（アライメント）が存在することが実験的に示されている [12].

Goldstein らは、治療抵抗性てんかんのため頭蓋内電極を留置していた患者 4 名を対象に、入院中に家族、友人、医師、病院スタッフらと交わした自然な日常会話を記録した。患者が自由に会話している間の ECoG と音声とを 24 時間体制で収集し、発話産出および音声理解を合わせた約 100 時間、約 52 万語のデータを解析した。

研究者らは、音声認識モデル Whisper のエンコーダおよびデコーダから、音響・音声・言語に対応する埋め込み表現を抽出し、それらから各 ECoG 電極の神経活動を線形エンコーディングモデルによって予測した。

その結果、Whisper の音声埋め込みは、上側頭回（STG）や前中心回・後中心回などの音声知覚・発話関連の感覚運動領域の活動を相対的によく説明し、言語埋め込みは、下前頭回（IFG）、角回（AG）、後部中側頭回（pMTG）などの高次言語関連領域の活動を相対的によく説明した。ただし、これらの領域は完全に分離された機能モジュールではなく、音声表現と言語表現の双方が広範な領域の活動を説明する混合的な表現も確認された。

時間的には、発話産出において、IFG における言語埋め込みの予測ピークが、感覚運動領域における音声埋め込みの予測ピークに先行した。一方、音声理解では、STG における音声埋め込みの予測ピークに続いて、IFG における言語埋め込みの予測ピークが現れた。この結果は、発話産出と音声理解において、モデル表現と脳活動の対応関係が異なる時間的順序を示すことを示唆する。

以上の結果は、Whisper の内部表現と、人間の言語関連脳活動との間に、自然会話中でも予測可能な機能的整合性が存在することを示す。ただし、この研究は、Whisper と人間の脳が同一の計算原理を実装していること、あるいは脳内の因果的な情報処理経路を Whisper がそのまま再現していることを証明したものではない。

4 提案手法（聴覚音声認識の脳型 SNN システム）

本研究で提案するシステムは、人間の耳（蝸牛）から脳の一次・二次聴覚野（STG）、そして音素列を認識する言語野への一連の情報流を忠実に模倣した **4 つのステージ** から構成される。全体構成を図 1 に示す。

4.1 Stage 1: 音声のスパイク化（入力層・耳）

入力された連続音声波形は、MATLAB 上に実装した生体模倣聴覚符号化（BAE）アルゴリズム [32] によって、**620 次元のスパイク列**（20 周波数チャンネル × 31 閾値ニューロン）へと変換される。処理プロセスは以下のステップから構成される。


1. コクリア・フィルタバンク（内耳）：

入力音声信号 x に対し、中心周波数が等価矩形帯域（ERB）スケールまたは CQT（Constant Q Transform）に基づき対数配置された $K = 20$ 個のフィルタを用いて、時間領域での畳み込みを並列実行し、各周波数チャンネル subband $y_k(t)$ を抽出する。


2. 対数フレームエネルギー算出：

30 ms の窓長、15 ms のスライド幅でサブバンド信号をフレーム化し、以下の対数フレームエネルギー


【入力音声波形】



【620 次元スパイク列 (Spike-TIMIT / Spike-Podcast)】



【300 次元 SNN 状態ダイナミクス】



【認識された音素列】

図 1 提案する脳型聴覚音声認識システムの全体像

$e_k(j)$ を計算し, 2 次元の時間-周波数スペクトログラム $S_{K \times N}$ を得る.

$$e_k(j) = 10 \log_{10} \left(\sum_{q=1}^l x_{kq}^2 \right) \quad (2)$$

3. 音響心理マスキング処理 (冗長性のカット) :

周波数軸方向の同時マスキング閾値 $T_a(f)$ (式 3) と, 時間軸方向の時間マスキング閾値 $y(n)$ (式 4) を計算し, その最大値を全体マスキング閾値 m_{ij} とする.

$$T_a(f) = 3.64 \left(\frac{f}{1000} \right)^{-0.8} - 6.5e^{-0.6 \left(\frac{f}{1000} - 3.3 \right)^2} + 0.001 \left(\frac{f}{1000} \right)^4 \quad (3)$$

$$y(n) = c^n \cdot p_1 \quad (4)$$

ここで, c は指数減衰定数, p_1 は直前のローカルピークにおけるスペクトルパワー強度である. 全体の 2 次元マスキングマップ $\Phi_{K \times N}(\phi_{ij})$ は次式で二値化され, スペクトログラム S にハダマル積として適用される.

$$\phi_{ij} = \begin{cases} 1 & \text{if } s_{ij} \geq m_{ij} \\ 0 & \text{if } s_{ij} < m_{ij} \end{cases} \quad (5)$$

4. 閾値コーディング (Threshold-crossing) :

マスキングを通過したフレームエネルギーに対し, 31 個の均等に配置されたエネルギー閾値 T_θ を超える瞬間にスパイク (発火事象) を発生させる. これにより, エネルギーの動的な「変動軌跡」のみを追従した極めてスパースで情報量の豊富な 620 次元のスパイク列 $P_{\text{mask}} = P_{K \times N} \circ \Phi_{K \times N}$ が生成される.

4.2 Stage 2: Predictive E-prop RSNN の自律学習（隠れ層・聴覚野 STG）

生成された 620 次元の入力スパイクは、適応閾値を持つ ALIF (Adaptive Leaky Integrate-and-Fire) ニューロンおよび通常の LIF ニューロンから構成される回帰型スパイクニューラルネットワーク (RSNN, ニューロン数: 300 個) に供給される。

通常, RSNN の学習には時間展開が必要な大域的な BPTT が使用されるが, 本研究では, 自己教師あり予測誤差最小化タスクにおいて生物学的に妥当なオンライン学習を実現するため, **Predictive E-prop** [29] を採用する. これは, 回帰型スパイクニューラルネットワーク (RSNN) のローカル学習則である **E-prop** [3] を予測符号化の目的関数に適用したものである. 学習タスクには正解ラベル (音素) を用いず, 現在のニューロン活動から「次のミリ秒の入力スパイク変動」を予測する **自己教師あり前向き予測 (Predictive SSL)** を課す.

各ニューロンの膜電位 $v_j(t)$ および閾値 $A_j(t)$ のダイナミクスは以下のように表される.

$$v_j(t+1) = \alpha v_j(t) + \sum_i w_{ji}^{\text{in}} x_i(t) + \sum_i w_{ji}^{\text{rec}} z_i(t) - z_j(t) v_{\text{th}} \quad (6)$$

E-prop では, 重みの更新勾配 Δw_{ji} を, 各ニューロンの局所的な情報である「適格性トレース (Eligibility Trace)」 $e_{ji}(t)$ と, トップダウンにフィードバックされる「学習シグナル (Learning Signal)」 $L_j(t)$ の積のオンライン累積として算出する.

$$\Delta w_{ji} = \eta \sum_t L_j(t) \cdot e_{ji}(t) \quad (7)$$

これにより, 将来の入力を前向きに予測するプロセス (Predictive SNN) において, 時間方向の逆伝播なしに RSNN の再帰シナプス重み W^{rec} が自律学習 (自己組織化) される.

4.3 Stage 3: SNN 活動解析および ECoG データとの相関・アライメント分析（可視化・分析）

学習された LIF/ALIF ニューロンによる RSNN の内部ダイナミクスを分析し, 生物学的な妥当性を検証するために, 本研究では単純な線形回帰マッピングに依存しない多角的な分析を行う.

1. ラスタープロット (Raster Plot):

300 個のニューロンの発火パターンを時間軸に対して並べ, 母音・子音や各音素, および音響インパルスに対する協調発火動態, ALIF による長い時間依存性の保持能力を視覚的に評価する.

2. 潜在空間の幾何学的軌跡解析 (Trajectory Analysis):

RSNN の隠れ状態の平滑化出力 $\tilde{z}_t \in \mathbb{R}^{300}$ を, PCA (主成分分析) や t-SNE によって 2 次元・3D へと圧縮投影する. 音素カテゴリごとに内部状態空間の軌跡 (Trajectory) が明確にクラスター化 (Clustering) され, 音素の境界を明瞭に区別してダイナミクスが遷移していく様子を解析する.

3. 頭蓋内脳電図 (ECoG) データとの機能的・表現的整合性 (アライメント) 分析:

OpenNeuro で公開されている 30 分間の Podcast 聴取時の「"Podcast" ECoG dataset」を用いて, 本モデルの「生物学的妥当性」を多角的に評価する. 脳データへの恣意的なフィッティング (回帰重みの学習) を排除し, モデルが持つ表現トポロジーやスパイクの時間動態そのものをダイレクトに比較するため, 以下の 4 つのアプローチを検討・適用する.

- **A) 線形エンコーディングモデル (Ridge Regression) [従来のフィッティングアプローチ]:**

ECoG 実験で用いられた同一の Podcast 音響波形を本モデルに入力し、Stage 2 で得られた RSNN の隠れ層ダイナミクス $\bar{z}_t$ から、患者の一次聴覚野 (STG など) における High-gamma 帯域 (75-200Hz) の時間変動脳活動波形 $r(t)$ を予測する Ridge 回帰モデルを構築する (図 2).

$$\hat{r}(t) = \beta^\top \bar{z}_t \quad (8)$$

未知のテスト音声に対する、モデル予測値 $\hat{r}(t)$ と実際の脳活動 $r(t)$ のピアソン相関 (Pearson's r) を計算する.

【Podcast 音響波形】

|
[本提案モデル]

|
(隠れ層の表現 $\bar{z}_t$) ---> [線形マッピング (Ridge 回帰)] ---> [予測された脳活動 $\hat{r}(t)$]
| (ピアソン相関 r)
v
【実際の ECoG 活動 $r(t)$ 】

図 2 線形エンコーディングモデルを用いたモデルと脳活動の相関分析

- **B) 表現類似性解析 (Representational Similarity Analysis: RSA) [パラメータフリーの幾何学的アライメント]:**

モデルが獲得した「音 (刺激) の類似度関係 (幾何学的トポロジー)」と、人間の脳が感じている「類似度関係」がどれだけ一致しているかをダイレクトに比較する [19].

具体的には、同一の音声刺激セット (代表的な単語や母音音素など) に対する SNN の平滑化活動 $\bar{z}_t$ から、刺激ペア間のコサイン距離や相関距離を計算し、 $N \times N$ のモデル表現選別行列 (RDM_{SNN} : Representational Distance Matrix) を作成する. 同様に、同一刺激に対する ECoG 電極群 (STG など) の High-gamma 応答から $N \times N$ の RDM_{ECoG} を構築する. この 2 つの RDM の下三角成分同士の相関係数を直接算出する (図 3). これにより、回帰のようなマッピングの重みを学習させる必要が一切なく、表現の類似性をダイレクトに比較可能である.

$$\text{RSA-alignment} = \text{corr}(\text{vech}(\text{RDM}_{\text{SNN}}), \text{vech}(\text{RDM}_{\text{ECoG}})) \quad (9)$$

- **C) Centered Kernel Alignment (CKA) [高次元表現空間のダイレクトアライメント]:**

SNN の時系列活動行列 $X \in \mathbb{R}^{T \times 300}$ と、ECoG の活動行列 $Y \in \mathbb{R}^{T \times C}$ (C は電極数) について、サンプルの時間スケールを合わせた状態で、表現類似性を線形または非線形カーネルを用いて 0 から 1 の値でダイレクトに算出する [18]. これにより、次元数が全く異なる隠れ層と皮質表現のダイナミクスの整合性を、重みの学習を挟むことなく定量化できる.

- **D) Spike-Field Coherence (SFC) & Spike-Triggered Average (STA) [スパイク-場電位レベルの時系列同期解析]:**

SNN が持つ「離散パルス発火 (スパイク)」という特性を活かし、ECoG という連続場電位 (LFP に相当) との時系列・周波数領域での直接的な同期動態を評価する [10].

SNN の特定のニューロンがスパイクを発火したタイミング (時刻 t_{spike}) の前後数ミリ秒における ECoG




図3 表現類似性解析 (RSA) による脳とモデルのトポロジー的直接アライメント評価

の High-gamma 振幅や、特定の周波数帯（例えば低周波オシレーションの位相）を抽出し、それらを加算平均して「スパイク誘発電位（STA：Spike-Triggered Average）」を構築する．STA に明瞭な時間的波形が浮かび上がる，あるいはスパイク発火タイミングと ECoG のオシレーション位相に強い位相コヒーレンス（Spike-Field Coherence: SFC）が確認される場合，SNN の個々のニューロン発火が，実際の生体脳のニューロン集団の同期活動とミリ秒レベルで直接同期・カップリングしていることをダイレクトに証明できる．

4.4 Stage 4: 線形デコーダによる音素分類（出力層・言語野）

自律学習した RSNN の再帰重み W^{rec} を完全に固定し，その上にシンプルな 1 層の**線形全結合層（Linear Readout Decoder）**を追加して音素分類を実行する．

- **目的:**

線形デコーダという極めて表現力の限定された分類器で高精度な音素抽出（分類）が達成できること自体が，前段の Predictive E-prop RSNN の内部状態空間において，各音素情報が「線形分離可能な形」で高度に自己組織化（整理）されていることを示す．

- **学習手法:**

TIMIT データセットの各音声フレームに紐付けられた音素ラベルアライメント（.phn）を正解（教師）信号とし，音素クロスエントロピー損失または CTC（Connectionist Temporal Classification）損失関数を用いてデコーダの出力接続重み W^{out} のみを高速に教師あり学習させる．これにより，End-to-End の音素列出力システムが完成する．

5 現在の状況と今後の実験計画

5.1 現在までの進捗状況

現在，提案システムにおける開発のフェーズは以下の状況にある．

1. Stage 1: 音声のスパイク化 (BAE フロントエンド) の MATLAB 実装完了 (進捗 100%) :

BAE ツール群の実装と、入力連続波形から 620 次元のスパイク列を生成するエンコーダプログラムが完成している。テスト音声 (Podcast) を適用し、同時マスキング $Ta(f)$ および時間マスキングの計算、および閾値判定により、音声の情報ダイナミクスを前向きに保持したまま、スパースなスパイク列が正常に出力されることを波形・ラスタプロットにて確認・検証済みである。

2. Stage 2: Predictive E-prop RSNN の自律学習の再現検証 (進捗 40%) :

Predictive E-prop アルゴリズム [29] の再現・検証コードを構築中である。現在は、公開されている既存文献のベンチマーク実験 (合成信号や簡易時系列タスク) を用いて、大域的 BPTT を用いない適格性トレースによるオンライン重み更新が意図通り安定して収束するかどうかの、再現検証を行っている段階である。

5.2 今後の実験計画

今後の中間・最終報告に向け、以下のステップで実証評価を進める。

● ステップ 1 : Stage 1 と Stage 2 の接続:

構築した BAE エンコーダで変換した TIMIT データおよび Podcast 音声のスパイク列を、Predictive E-prop RSNN の入力としてパイプライン接続する。高次元 (620 次元) スパイク列の時間変動予測タスクにおいて、自律学習 (RSNN 再帰重みの更新) を動作させ、膜電位や適格性トレースの安定性をチューニングする。

● ステップ 2 : 線形デコーダ接続による音声認識性能の測定:

TIMIT データセットを用いて線形 Readout デコーダを学習させ、フレームごとの音素分類精度、および CTC を用いた音素エラー率 (PER : Phone Error Rate) を算出する。同時に、計算中の累積スパイク発火数をカウントすることで、従来の ANN と比較した際のモデルの「極めて高いエネルギー効率 (スパース通信効果)」を定量化して検証する。

● ステップ 3 : 内部ダイナミクス可視化とクラスタリング分析:

学習済みモデルの隠れ層発火からラスタプロットを出力する。また、各フレームでの 300 次元状態を PCA/t-SNE によって低次元展開し、状態軌跡が母音 ($/a/$, $/i/$, $/u/$ 等) や子音といった音響音素カテゴリごとに空間上でどのように幾何学的なクラスターを形成するか、その自己組織化能力を視覚的に評価する。

● ステップ 4 : ECoG データとの脳活動機能的整合性・直接アライメント評価:

OpenNeuro の「Podcast」ECoG dataset」を活用し、図 2 に示す線形エンコーディングモデル (Ridge 回帰) に加え、パラメータフィッティングを必要としない表現類似性解析 (RSA), Centered Kernel Alignment (CKA), および Spike-Field Coherence (SFC) や Spike-Triggered Average (STA) を用いたスパイク-LFP 直接同期解析を実装する。本モデルの隠れ層発火およびダイナミクスと、実被験者の一次聴覚野 (STG) や言語エリア (IFG など) における High-gamma 神経活動の間のアライメントスコアを、トポロジー幾何・時系列同期・予測精度の多角的な視点から算出し、生物学的な妥当性を学術的に徹底検証する。

6 まとめ

本研究は、現代 AI の課題であるエネルギー非効率性を克服するために、脳の低電力動作原理 (SNN + 予測符号化) を音声認知システムへと拡張する先進的な試みである。

これまでに、耳・蝸牛の精緻な符号化と心理音響マスキングを模倣した「Stage 1 (BAE)」の開発を完了し、現在、聴覚野に相当する自律的予測学習システム「Stage 2 (Predictive E-prop RSNN)」の再現および数理的な調整を進めている。

今後は、Stage 1 と 2 の統合を進めるとともに、OpenNeuro 公開の「"Podcast" ECoG」脳信号データセットとの機能的整合性分析（脳活動アライメント評価）を行い、本提案モデルが脳の音声・言語処理プロセスをどの程度忠実に自己組織化できているかを検証する。この結果は、学術的な計算論的神経科学への貢献だけでなく、次世代の省電力ニューロモルフィックエッジハードウェア向けの音声認識・聴覚センサーフロントエンド技術としての応用展開が期待される。

参考文献

- [1] E. D. Adrian and Y. Zotterman. The impulses produced by sensory nerve endings: Part 3: Impulses set up by touch and pressure. *The Journal of Physiology*, 61(4):465, 1926.
- [2] S. Baek and J. Lee. Snn and sound: a comprehensive review of spiking neural networks in sound. *Biomedical Engineering Letters*, 14(5):981–991, 2024.
- [3] G. Bellec, F. Scherr, A. Subramoney, E. Hajek, D. Salaj, R. Legenstein, and W. Maass. A solution to the learning dilemma for recurrent networks of spiking neurons. *Nature communications*, 11(1):3625, 2020.
- [4] G. Q. Bi and M. M. Poo. Synaptic modifications in cultured hippocampal neurons: dependence on spike timing, synaptic strength, and postsynaptic cell type. *Journal of Neuroscience*, 18(24):10464–10472, 1998.
- [5] Y. Cao, Y. Chen, and D. Khosla. Spiking deep convolutional neural networks for energy-efficient object recognition. *International Journal of Computer Vision*, 113(1):54–66, 2015.
- [6] X. Chen, Q. Yang, J. Wu, H. Li, and K. C. Tan. A hybrid neural coding approach for pattern recognition with spiking neural networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2023.
- [7] P. U. Diehl, D. Neil, J. Binas, M. Cook, S. C. Liu, and M. Pfeiffer. Fast-classifying, high-accuracy spiking deep networks through weight and threshold balancing. In *International Joint Conference on Neural Networks (IJCNN)*, pp. 1–8, 2015.
- [8] M. Dong, X. Huang, and B. Xu. Unsupervised speech recognition through spike-timing-dependent plasticity in a convolutional spiking neural network. *PLoS One*, 13(11):e0204596, 2018.
- [9] C. Eliasmith and C. H. Anderson. *Neural engineering: computation, representation, and dynamics in neurobiological systems*. MIT Press, 2003.
- [10] P. Fries. A mechanism for cognitive dynamics: neuronal communication through neuronal coherence. *Trends in cognitive sciences*, 9(10):474–480, 2005.
- [11] W. Gerstner, W. M. Kistler, R. Naud, and L. Paninski. *Neuronal dynamics: From single neurons to networks and models of cognition*. Cambridge University Press, 2014.
- [12] A. Goldstein, H. Wang, L. Niekerken, M. Schain, Z. Zada, B. Aubrey, T. Sheffer, S. A. Nastase, H. Gazula, A. Singh, et al. A unified acoustic-to-speech-to-language embedding space captures the neural basis of natural language processing in everyday conversations. *Nature human behaviour*,

- 9(5):1041–1055, 2025.
- [13] W. Guo, M. E. Fouda, A. M. Eltawil, and K. N. Salama. Neural coding in spiking neural networks: a comparative study for robust neuromorphic systems. *Frontiers in Neuroscience*, 15:638474, 2021.
 - [14] B. Han, G. Srinivasan, and K. Roy. Rmp-snn: Residual membrane potential neuron for enabling deeper high-accuracy and low-latency spiking neural network. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 13555–13564, 2020.
 - [15] S. Herculano-Houzel. Scaling of brain metabolism with a fixed energy budget per neuron: implications for neuronal activity, plasticity and evolution. *PloS one*, 6(3):e17514, 2011.
 - [16] L. A. Jeffress. A place theory of sound localization. *Journal of Comparative and Physiological Psychology*, 41(1):35, 1948.
 - [17] V. Karlsson, N. Fianda, and J.-K. Kamarainen. Difference predictive coding for training spiking neural networks. In *International Conference on Learning Representations*, Vol. 2026, pp. 104022–104041, 2026.
 - [18] S. Kornblith, M. Norouzi, H. Lee, and G. Hinton. Similarity of neural network representations revisited. In *International conference on machine learning*, pp. 3519–3529. PMIR, 2019.
 - [19] N. Kriegeskorte, M. Mur, and P. A. Bandettini. Representational similarity analysis-connecting the branches of systems neuroscience. *Frontiers in systems neuroscience*, 2:249, 2008.
 - [20] B. M. Lake, T. D. Ullman, J. B. Tenenbaum, and S. J. Gershman. Building machines that learn and think like people. *arXiv preprint arXiv:1604.00289*, 2016.
 - [21] J. H. Lee, T. Delbruck, and M. Pfeiffer. Training deep spiking neural networks using backpropagation. *Frontiers in Neuroscience*, 10:228000, 2016.
 - [22] Q. Liu, D. Xing, L. Feng, H. Tang, and G. Pan. Event-based multimodal spiking neural network with attention mechanism. In *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 8922–8926, 2022.
 - [23] F. Martinelli, G. Dellaferera, P. Mainar, and M. Cernak. Spiking neural networks trained with backpropagation for low power neuromorphic implementation of voice activity detection. In *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 8544–8548, 2020.
 - [24] T. Masquelier and S. J. Thorpe. Unsupervised learning of visual features through spike timing dependent plasticity. *PLoS Computational Biology*, 3(2):e31, 2007.
 - [25] M. McCloskey and N. J. Cohen. Catastrophic interference in connectionist networks: The sequential learning problem. In *Psychology of learning and motivation*, Vol. 24, pp. 109–165. Elsevier, 1989.
 - [26] B. Millidge, A. Seth, and C. L. Buckley. Predictive coding: a theoretical and experimental review. *arXiv preprint arXiv:2107.12979*, 2021.
 - [27] M. Miskowicz. Send-on-delta concept: an event-based data reporting strategy. *Sensors*, 6(1):49–63, 2006.
 - [28] E. O. Neftci, H. Mostafa, and F. Zenke. Surrogate gradient learning in spiking neural networks: bringing the power of gradient-based optimization to spiking neural networks. *IEEE Signal Processing Magazine*, 36(6):51–63, 2019.
 - [29] D. Noè, H. Yamamoto, Y. Katori, and S. Sato. Predictive e-prop: A biologically inspired approach

- to train predictive coding-based recurrent spiking neural networks. *bioRxiv*, pp. 2026–02, 2026.
- [30] G. Oliviers, M. Tang, and R. Bogacz. Bidirectional predictive coding. In *International Conference on Learning Representations*, Vol. 2026, pp. 59585–59619, 2026.
 - [31] A. M. M. Oswald, B. Doiron, and L. Maler. Interval coding. i. burst interspike intervals as indicators of stimulus intensity. *Journal of Neurophysiology*, 97(4):2731–2743, 2007.
 - [32] Z. Pan, Y. Chua, J. Wu, M. Zhang, H. Li, and E. Ambikairajah. An efficient and perceptually motivated auditory neural encoding and decoding algorithm for spiking neural networks. *Frontiers in neuroscience*, 13:1420, 2020.
 - [33] S. S. Park and Y.-S. Choi. Spiking neural networks for physiological and speech signals: a review. *Biomedical Engineering Letters*, 14(5):943–954, 2024.
 - [34] D. Patterson, J. Gonzalez, Q. Le, C. Liang, L.-M. Munguia, D. Rothchild, D. So, M. Texier, and J. Dean. Carbon emissions and large neural network training. *arXiv preprint arXiv:2104.10350*, 2021.
 - [35] F. Ponulak and A. Kasinski. Introduction to spiking neural networks: Information processing, learning and applications. *Acta Neurobiologiae Experimentalis*, 71(4):409–433, 2011.
 - [36] N. Rathi and K. Roy. Stdp based unsupervised multimodal learning with cross-modal processing in spiking neural networks. *IEEE Transactions on Emerging Topics in Computational Intelligence*, 5(1):143–153, 2018.
 - [37] D. E. Rumelhart, G. E. Hinton, and R. J. Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986.
 - [38] M. V. Srinivasan, S. B. Laughlin, and A. Dubs. Predictive coding: a fresh view of inhibition in the retina. *Proceedings of the Royal Society of London. Series B, Biological Sciences*, pp. 427–459, 1982.
 - [39] G. M. Van de Ven, H. T. Siegelmann, and A. S. Tolias. Brain-inspired replay for continual learning with artificial neural networks. *Nature communications*, 11(1):4069, 2020.
 - [40] P. J. Werbos. Backpropagation through time: what it does and how to do it. *Proceedings of the IEEE*, 78(10):1550–1560, 1990.
 - [41] 砂川恵太郎. 双方向予測符号化のスパイクニューラルネットワークへの実装による計算コストの削減. <https://tus.box.com/s/x7gc8ujqimsum79g2l5q28xwzvmstcvn>, 2026.